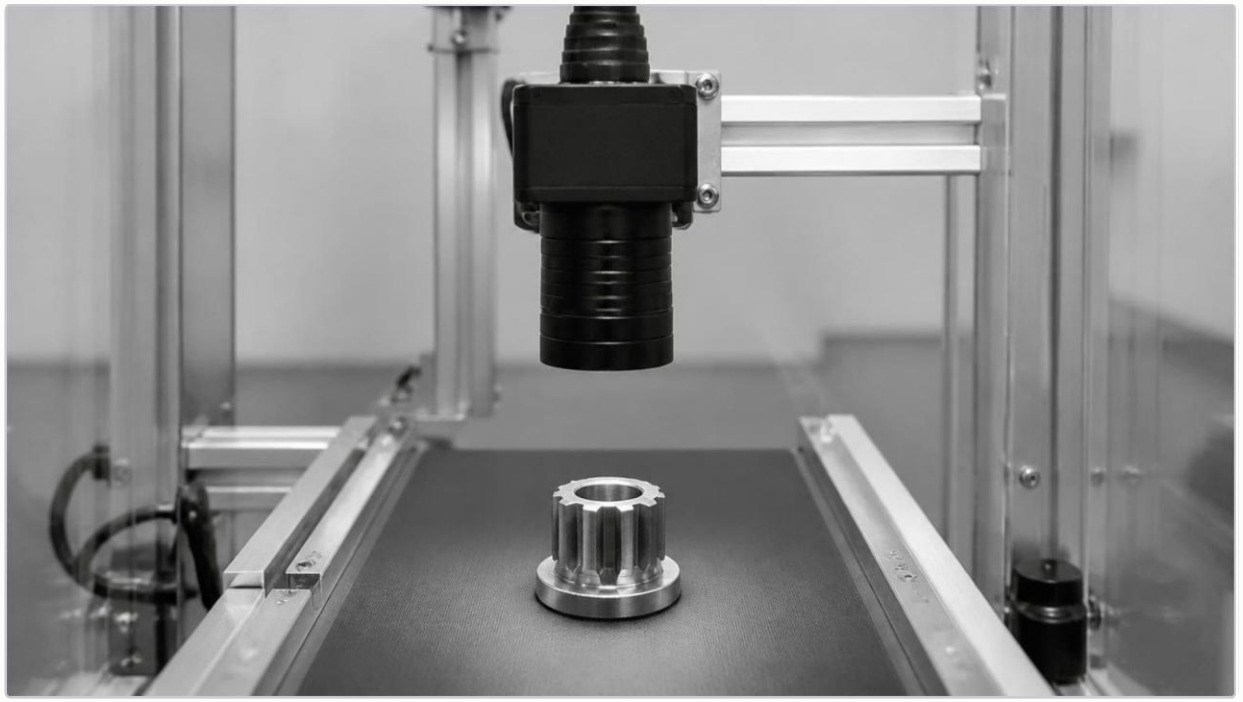
КОМПЬЮТЕРНОЕ ЗРЕНИЕ · ЛЕКЦИЯ 1–2

Современное компьютерное зрение: от CNN к foundation models, детекция и сегментация, SAM и open-vocabulary

Визуальные представления, локализация объектов и адаптация предобученных моделей.



СТРУКТУРА ЛЕКЦИИ

План лекции

01 **Современное CV: от CNN к foundation models**

Архитектуры, transfer learning и достоверность эксперимента.

---

02 **Детекция и сегментация объектов**

Постановки задач, данные, семейства моделей и метрики.

---

03 **Foundation models для сегментации и open-vocabulary**

SAM, текстовые запросы и автоматизация разметки.

---

04 **Итоги и контрольные вопросы**

Выбор решений и диагностика ошибок.

ТЕМА 1. СОВРЕМЕННОЕ CV: ОТ CNN К FOUNDATION MODELS

Представления, адаптация и честный эксперимент

ПРЕДСТАВЛЕНИЯ · ИСТОРИЯ

Три эпохи компьютерного зрения

Период	Парадигма	Что обучаем	Пример
До ~2012	Ручные признаки SIFT/HOG	Классификатор поверх признаков	HOG + SVM
2012–2020	Обучение представлений под задачу	Всю сеть	AlexNet, ResNet, Faster R-CNN
2020–н.в.	Предобученная модель + адаптация	Лёгкую голову, часть сети; либо prompting	CLIP, DINOv2, SAM, Grounding DINO

Повторное использование представлений становится базовой инженерной практикой.

ПРЕДСТАВЛЕНИЯ · СМЕНА ПАРАДИГМЫ

Главный вопрос сместился: какую модель взять и как её адаптировать

Предобучение один раз. Адаптация под задачу.

Модель обучается на огромных данных, часто со слабой разметкой. Дообучение, лёгкие головы и подсказки позволяют использовать её признаки, сохраняя обобщающую способность.

Выбор стратегии адаптации столь же важен, как выбор архитектуры.

CNN · БАЗОВЫЕ СВОЙСТВА

Свёртка: четыре свойства, на которых строится зрение

Локальность и разделение весов

Одно ядро применяется во всех позициях изображения.

Эквивариантность к сдвигу

Сдвиг входа сдвигает карту признаков; pooling добавляет частичную инвариантность.

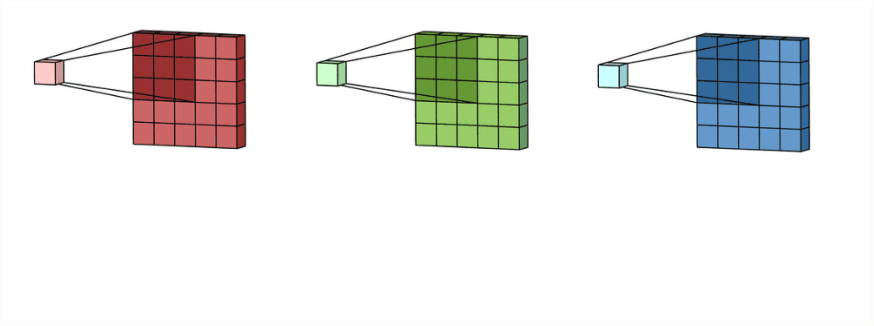
Рост рецептивного поля

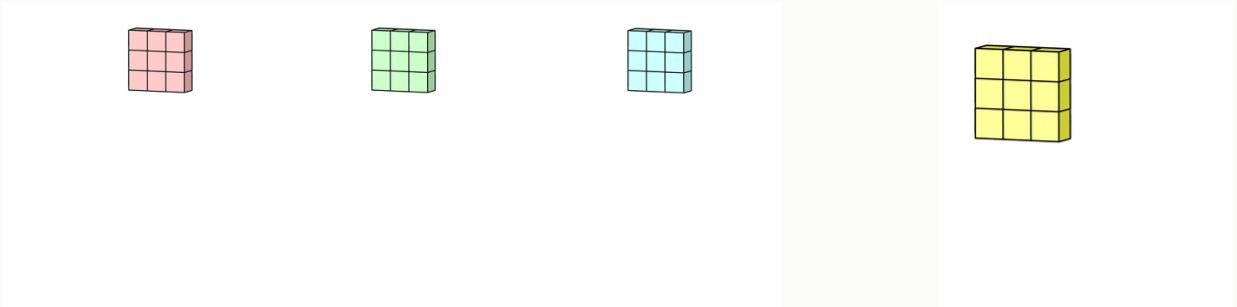
Глубокие признаки агрегируют всё более широкий контекст.

Иерархия признаков

Края → текстуры → части → объекты. Многоуровневые карты служат основой FPN.

224×224×3 → 224×224×64: свёртка 3×3 имеет 1 792 параметра с bias.





Две свёртки 3×3 выгоднее одной 5×5

Одна свёртка 5×5

$$R = 5, \qquad W = 25C^2$$

Один линейный оператор и одна нелинейность.

Две свёртки 3×3

$$R = 3 + (3 - 1) = 5$$

$$W = 18C^2$$

То же рецептивное поле, меньше весов и дополнительная нелинейность.

CNN · ОСТАТОЧНЫЕ СВЯЗИ

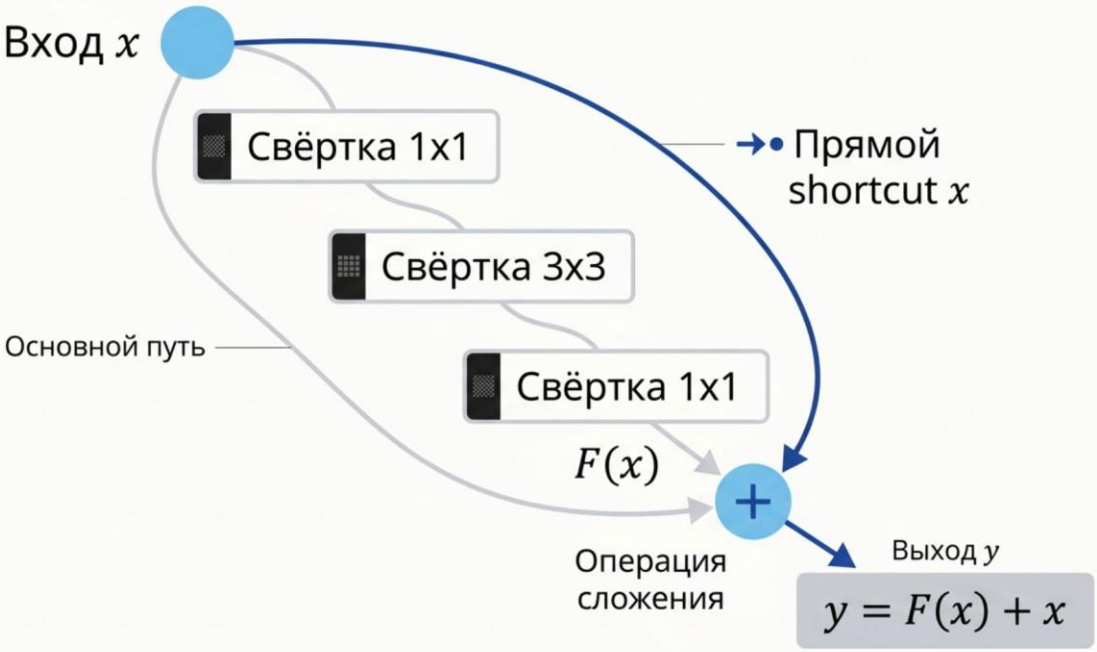
ResNet: остаточный блок решает проблему деградации

Рост ошибки на обучении при увеличении глубины указывает на трудность оптимизации, а не на переобучение.

$$y = F(x) + x$$

Блок учит поправку к тождественному отображению. Shortcut даёт прямой путь градиенту.

ResNet-50/101/152 используют bottleneck 1×1 → 3×3 → 1×1.



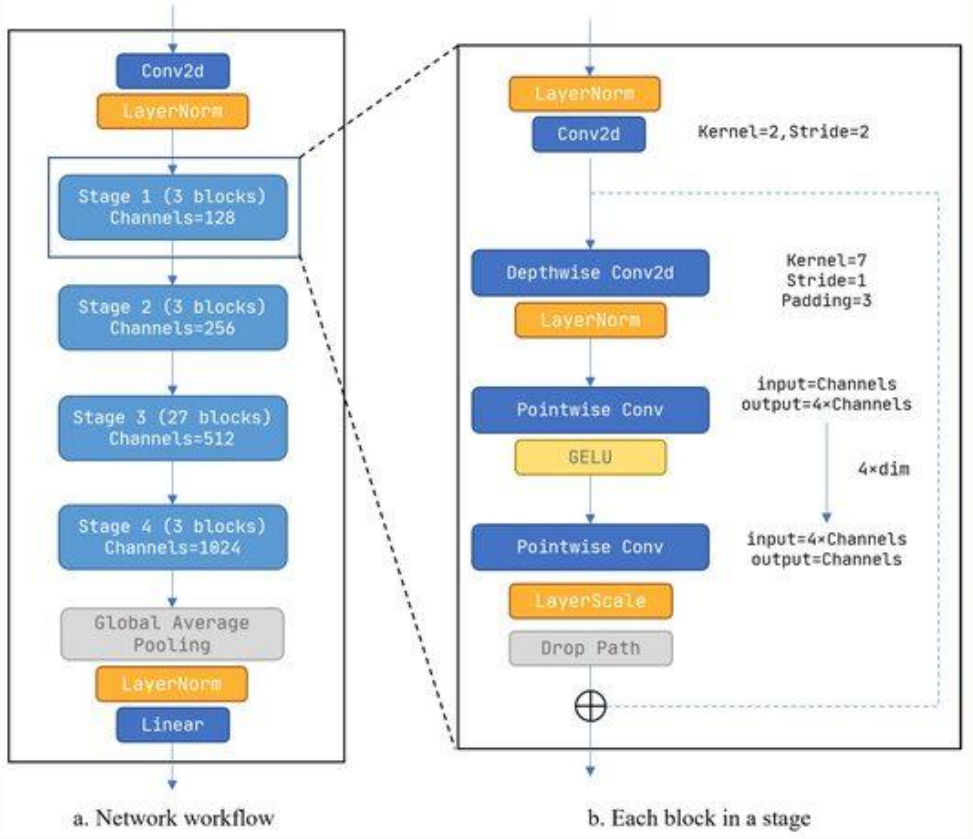
Stride 4, 8, 16, 32 → уровни C2–C5 для FPN.

CNN · СОВРЕМЕННЫЙ РЕЦЕПТ

ConvNeXt: CNN, модернизированный рецептами трансформеров

Разрыв CNN и ViT во многом определялся дизайном и обучением, а не только механизмом внимания.

Изменение	Откуда заимствовано
Рецепт обучения: AdamW, длинное обучение, Mixup/CutMix, RandAugment, stochastic depth	DeiT/Swin
Пропорции стадий 3:3:9:3	Swin
«Patchify» stem: свёртка 4×4 со stride 4	ViT/Swin
Depthwise-свёртка 7×7 (аналог локального окна внимания)	Swin
Inverted bottleneck (расширение ×4 в MLP)	Трансформерный MLP
LayerNorm вместо BatchNorm, GELU вместо ReLU, меньше нормализаций и активаций	Трансформеры



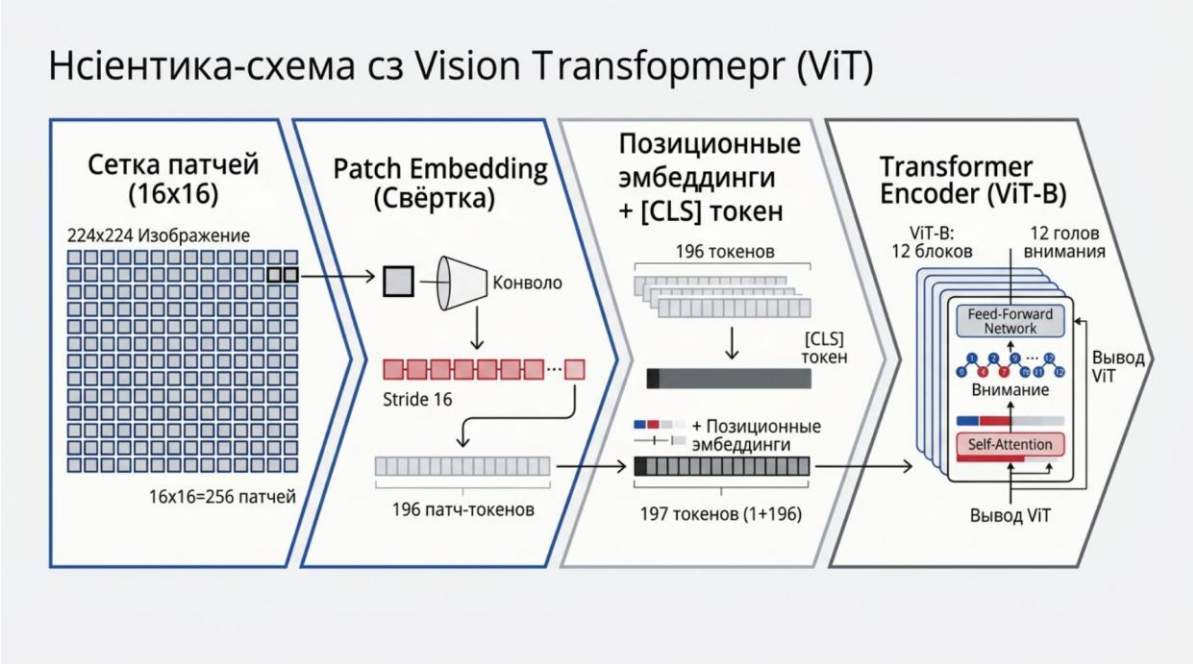
a. Network workflow

b. Each block in a stage

Практический выбор для средних данных, стабильности и экспорта на устройства.

VIT · ТОКЕНИЗАЦИЯ

Vision Transformer: изображение как последовательность патчей



Патчи P×P становятся векторами признаков. Порядок токенов задаётся позиционными эмбеддингами.

При смене разрешения позиционные эмбеддинги интерполируют bicubic. Ошибки интерполяции часто нарушают fine-tuning.

Квадратичная стоимость внимания мотивирует иерархические энкодеры

Изображение $x \in \mathbb{R}^{H \times W \times C}$ режется на $N = HW/P^2$ патчей размера $P \times P$

$$z^0 = [x_{class}; x^1_p E; x^2_p E; \cdots; x^N_p E] + E_{pos}, \quad E \in R^{(P^2C) \times D}, E_{pos} \in R^{(N+1) \times D}$$

x — исходное изображение;
P — размер патча;
N — количество патчей;
E — матрица проекции (обучаемая);
E_pos — матрица позиционных эмбеддингов (обучаемая);
x_class — обучаемый токен класса;

VIT · ВЫЧИСЛИТЕЛЬНАЯ СТОИМОСТЬ

Квадратичная стоимость внимания мотивирует иерархические энкодеры

½

Размер патча

По каждой пространственной оси.

×4

Число токенов

$$N = \frac{HW}{P^2}$$

×16

Стоимость внимания

Attention N^2

Оконное внимание и иерархия ограничивают стоимость: Swin, Hiera. SAM использует ViT-H с оконным вниманием; SAM 2 использует Hiera.

ПРЕДСТАВЛЕНИЯ · СРАВНЕНИЕ

Индуктивное смещение: CNN против ViT

Свойство	CNN	ViT
Локальность	Встроена ядром	Не задана жёстко
Сдвиг	Эквивариантность встроена	Зависит от обучения и позиции
Контекст	Расширяется с глубиной	Глобальный с первого слоя в vanilla ViT
Малые данные	Сильный prior помогает	Нужно сильное предобучение
Масштабирование	Насыщается раньше	Продолжает выигрывать от масштаба
Признаки для dense tasks	Естественная пирамида	Требует иерархии или адаптации

Сильное смещение даёт «бесплатные данные» на малой выборке, но ограничивает гибкость.

АДАПТАЦИЯ · ВЫБОР СТРАТЕГИИ

Три стратегии transfer learning

Linear probing

Энкодер заморожен; обучается линейная голова.

Для сотен примеров и близкого домена.

Минимальная стоимость и риск забывания.

Частичная разморозка

Обучаются голова и последние k блоков.

Для средних данных и умеренного доменного сдвига.

Компромисс между адаптацией и устойчивостью.

Полный fine-tuning

Обновляется вся сеть.

Для многих данных или сильного сдвига: медицина, спутники, ИК.

Максимальный риск забывания.

Усложнять адаптацию следует после измерения простого baseline.

АДАПТАЦИЯ · LP-FT

LP-FT: сначала голова, затем вся сеть

Случайная голова в начале fine-tuning создаёт большие градиенты и искажает предобученные признаки.

01

Linear probing

Заморозить энкодер и обучить голову на целевой задаче.

02

Fine-tuning

Разморозить сеть и продолжить обучение с подготовленной головой.

Подготовленная голова снижает искажение признаков и улучшает обобщение вне распределения.

Kumar et al., 2022. Эффект зависит от задачи и доменного сдвига.

АДАПТАЦИЯ · ОПТИМИЗАЦИЯ

Послойный learning rate защищает общие признаки

Вход и ранние блоки

Наименьший learning rate: общие визуальные признаки.

Поздние блоки

Более высокий learning rate: признаки целевой задачи.

Голова

Наибольший learning rate: новая граница решений.

Discriminative learning rates: backbone меньше, голова больше, как в ULMFiT.

LLRD уменьшает lr геометрически к входу трансформера.

Warmup 1–5% обучения + cosine decay. Weight decay не применяют к bias и нормализации.

Warmup - фаза линейного роста скорости обучения

$$\eta(t) = \eta_{min} + \tfrac{1}{2}(\eta_{max} - \eta_{min}) * (1 + \cos(\pi t/T))$$

300 рентгеновских снимков и ImageNet-модель: что пробовать первым?

ЭКСПЕРИМЕНТ · ВАЛИДНОСТЬ

Утечки данных завышают метрики

Общие группы

Снимки одного пациента или кадры одного видео должны оставаться в одном split. Использовать GroupKFold или StratifiedGroupKFold.

Дубликаты

Проверять хеш файла, pHash и близость эмбеддингов CLIP/DINOv2 для почти-дубликатов.

Предобработка

Аугментации выполнять после разбиения. Статистики нормализации оценивать только по train.

Использование test

Test используется один раз, в конце. Выбор модели и порогов выполняется на validation.

Независимость выборок важнее архитектурной находки.

ЭКСПЕРИМЕНТ · ВОСПРОИЗВОДИМОСТЬ

Воспроизводимость эксперимента

Повторяемость

Seed во всех библиотеках; минимум 3 запуска, среднее и разброс метрик.

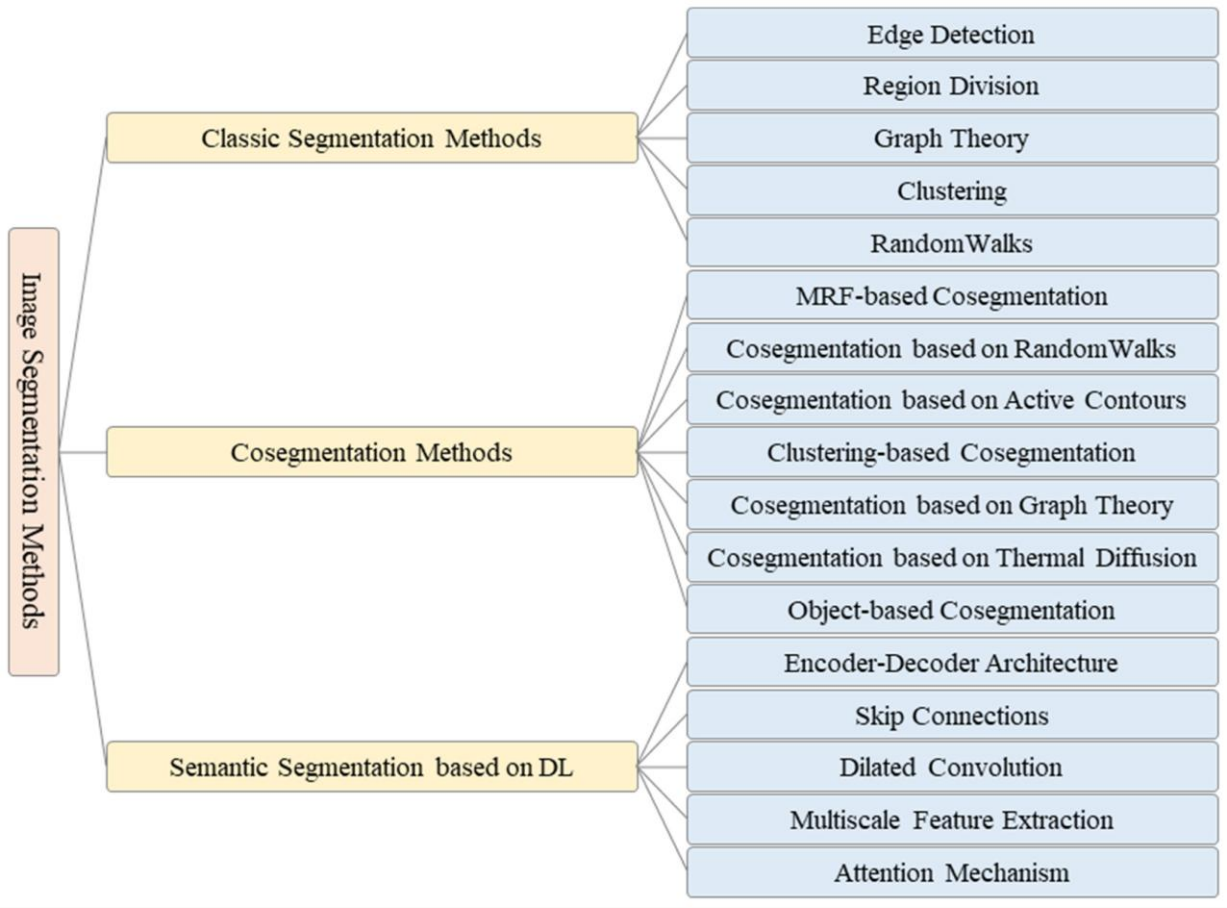
Прослеживаемость

Конфиги YAML, версии кода, библиотек и датасета; сохранённые списки разбиения.

Восстановление обучения

Чекпоинты с оптимизатором и RNG-состояниями; журнал метрик.

Baseline → одно изменение за раз → ablation.



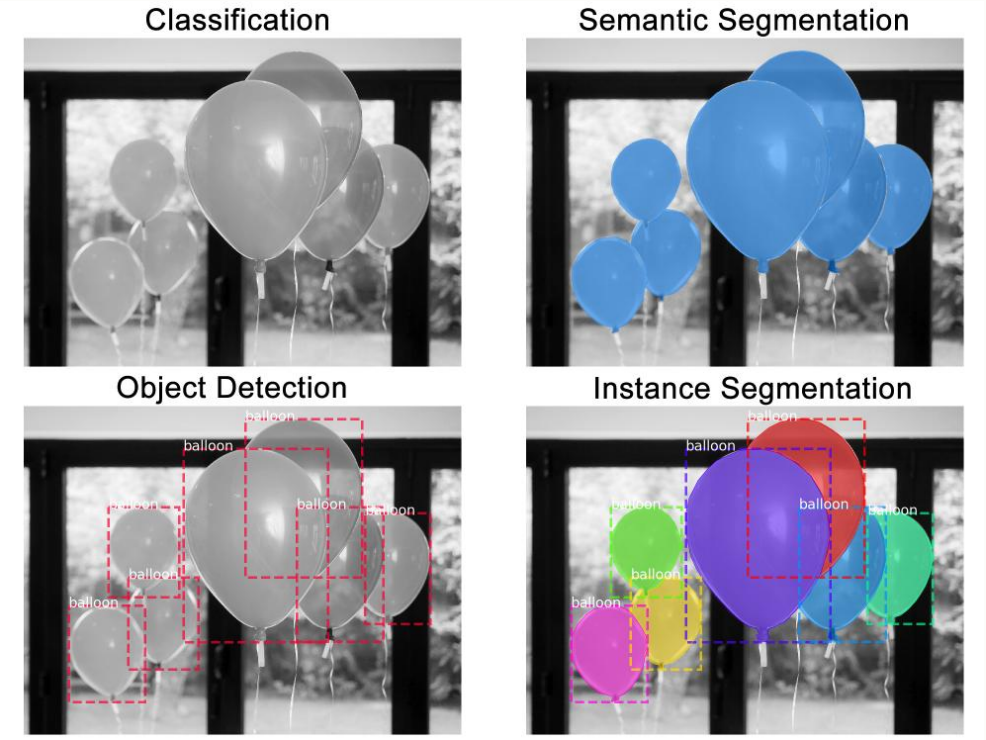
ТЕМА 2. ДЕТЕКЦИЯ И СЕГМЕНТАЦИЯ ОБЪЕКТОВ

Выход модели, качество данных и диагностика ошибок

ЗАДАЧИ · ПОСТАНОВКИ

Пять постановок задач компьютерного зрения

Задача	Выход	Instance	Stuff	Метрика
Classification	Класс кадра	Нет	Нет	Accuracy/F1
Detection	Боксы, классы	Да	Нет	mAP
Semantic	Класс пикселя	Нет	Да	mIoU/Dice
Instance	Маски объектов	Да	Нет	mask mAP
Panoptic	Класс + id	Да	Да	PQ



Instance означает различение отдельных экземпляров; stuff означает области фона.

ЗАДАЧИ · PANOPTIC

Panoptic segmentation объединяет things и stuff

Things

Счётные объекты: люди, машины.

Каждый объект получает собственный id экземпляра.

Stuff

Аморфные области: небо, дорога, трава.

Пиксели получают класс области без разделения на счётные экземпляры.

pixel (class, instance id)

$$PQ = \underbrace{\frac{\sum_{(p,g)\in TP} \mathrm{IoU}(p,g)}{|TP|}}_{SQ} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}}_{RQ},$$

Сопоставление сегментов засчитывается при IoU больше 0.5.

Kirillov et al., 2018. Метрика Panoptic Quality, PQ.

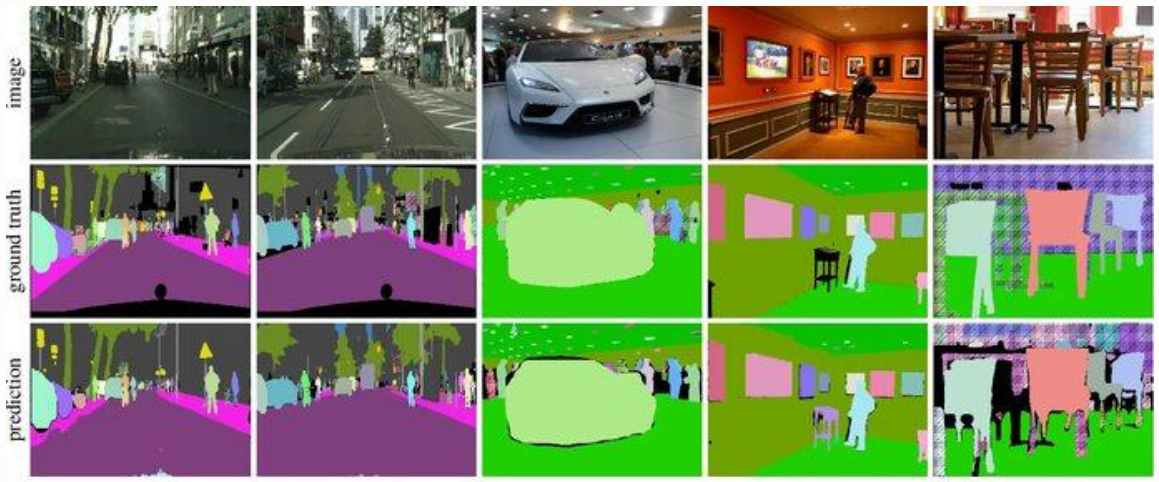


Figure 5: **Panoptic segmentation results** on Cityscapes (left two) and ADE20k (right three). Predictions are based on the merged outputs

ДЕТЕКЦИЯ · КОНВЕЙЕР

Общая схема детектора и постобработка NMS

1

Backbone

Входное изображение; извлечение признаков

2

Neck · FPN/PAN

Объединение масштабов

3

Head

Класс + бокс + score

4

Выход

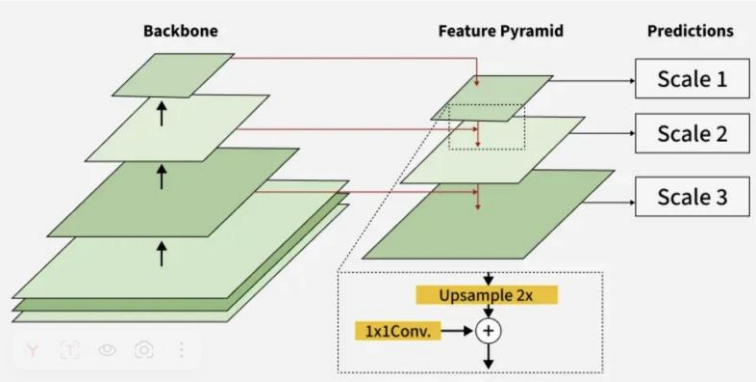
NMS или сопоставление «запрос — объект»

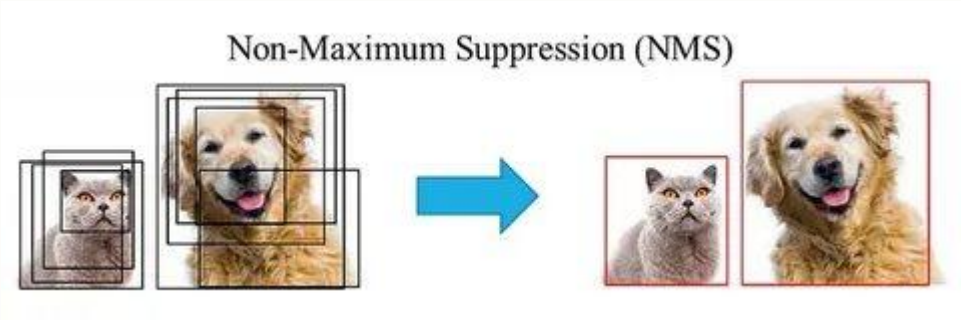
Алгоритм NMS

Сортировка по score; сохранение лучшего бокса; удаление пересечений с IoU выше порога 0.5–0.7; повторение.

Ограничения

Ручной порог, подавление соседних объектов в плотных сценах, нестабильное время постобработки.





ДЕТЕКЦИЯ · R-CNN

Двухстадийные детекторы: Faster R-CNN и Mask R-CNN

01

RPN

Region Proposal Network предлагает ~1–2 тыс. регионов по картам backbone.

02

RoI-признаки

Классификация предложений и уточнение координат боксов.

03

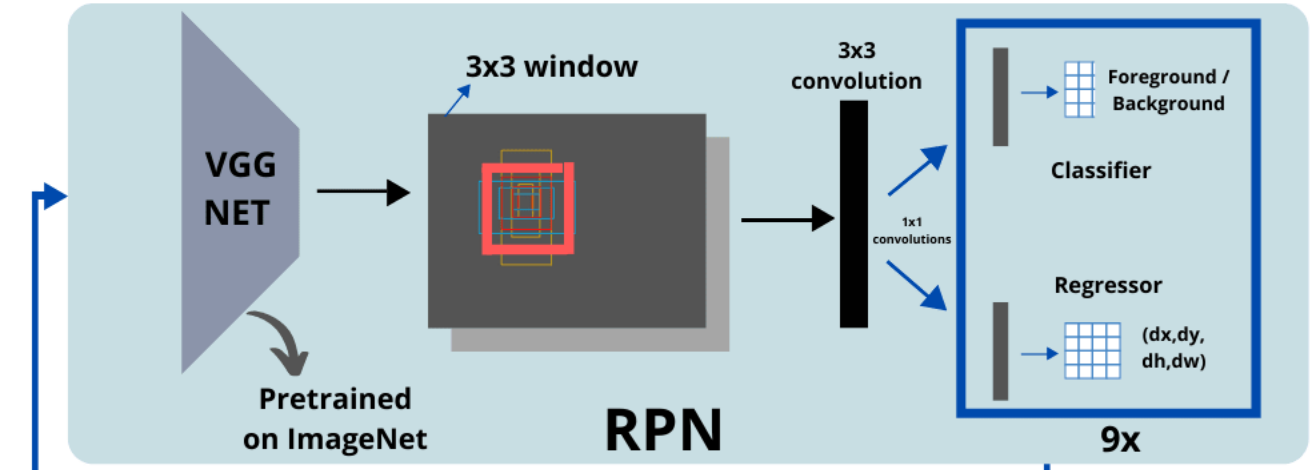
Mask head

Mask R-CNN добавляет маску. RoIAlign устраняет квантование координат.

Точная локализация; сильный исследовательский baseline для масок.

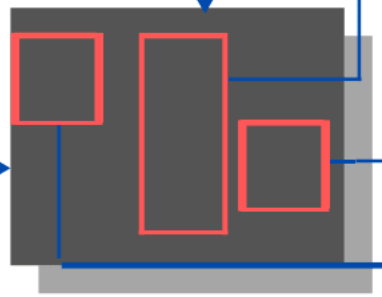
Медленнее одностадийных решений; сложнее развёртывание.

Faster R-CNN

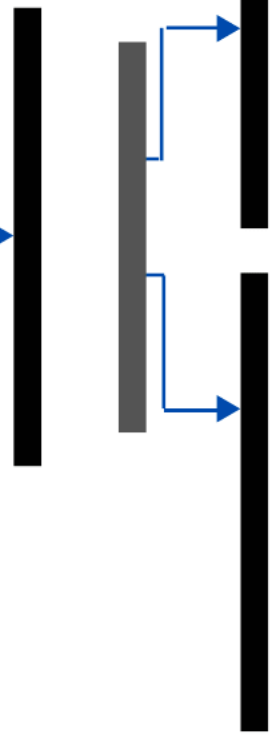

VGG
NET
3x3 window
3x3
convolution
1x1
convolutions
Foreground /
Background
Classifier
Regressor
(dx,dy,
dh,dw)
Pretrained
on ImageNet
RPN
9x

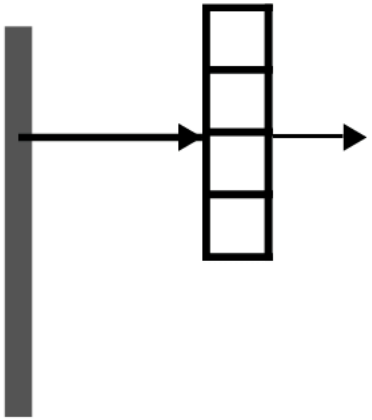


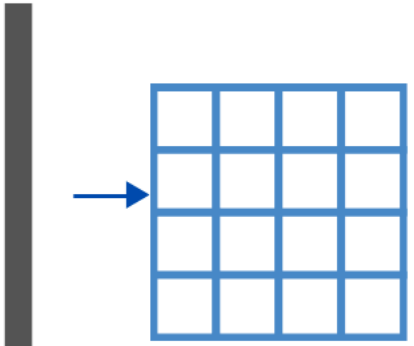

VGG NET
Pretrained
on ImageNet

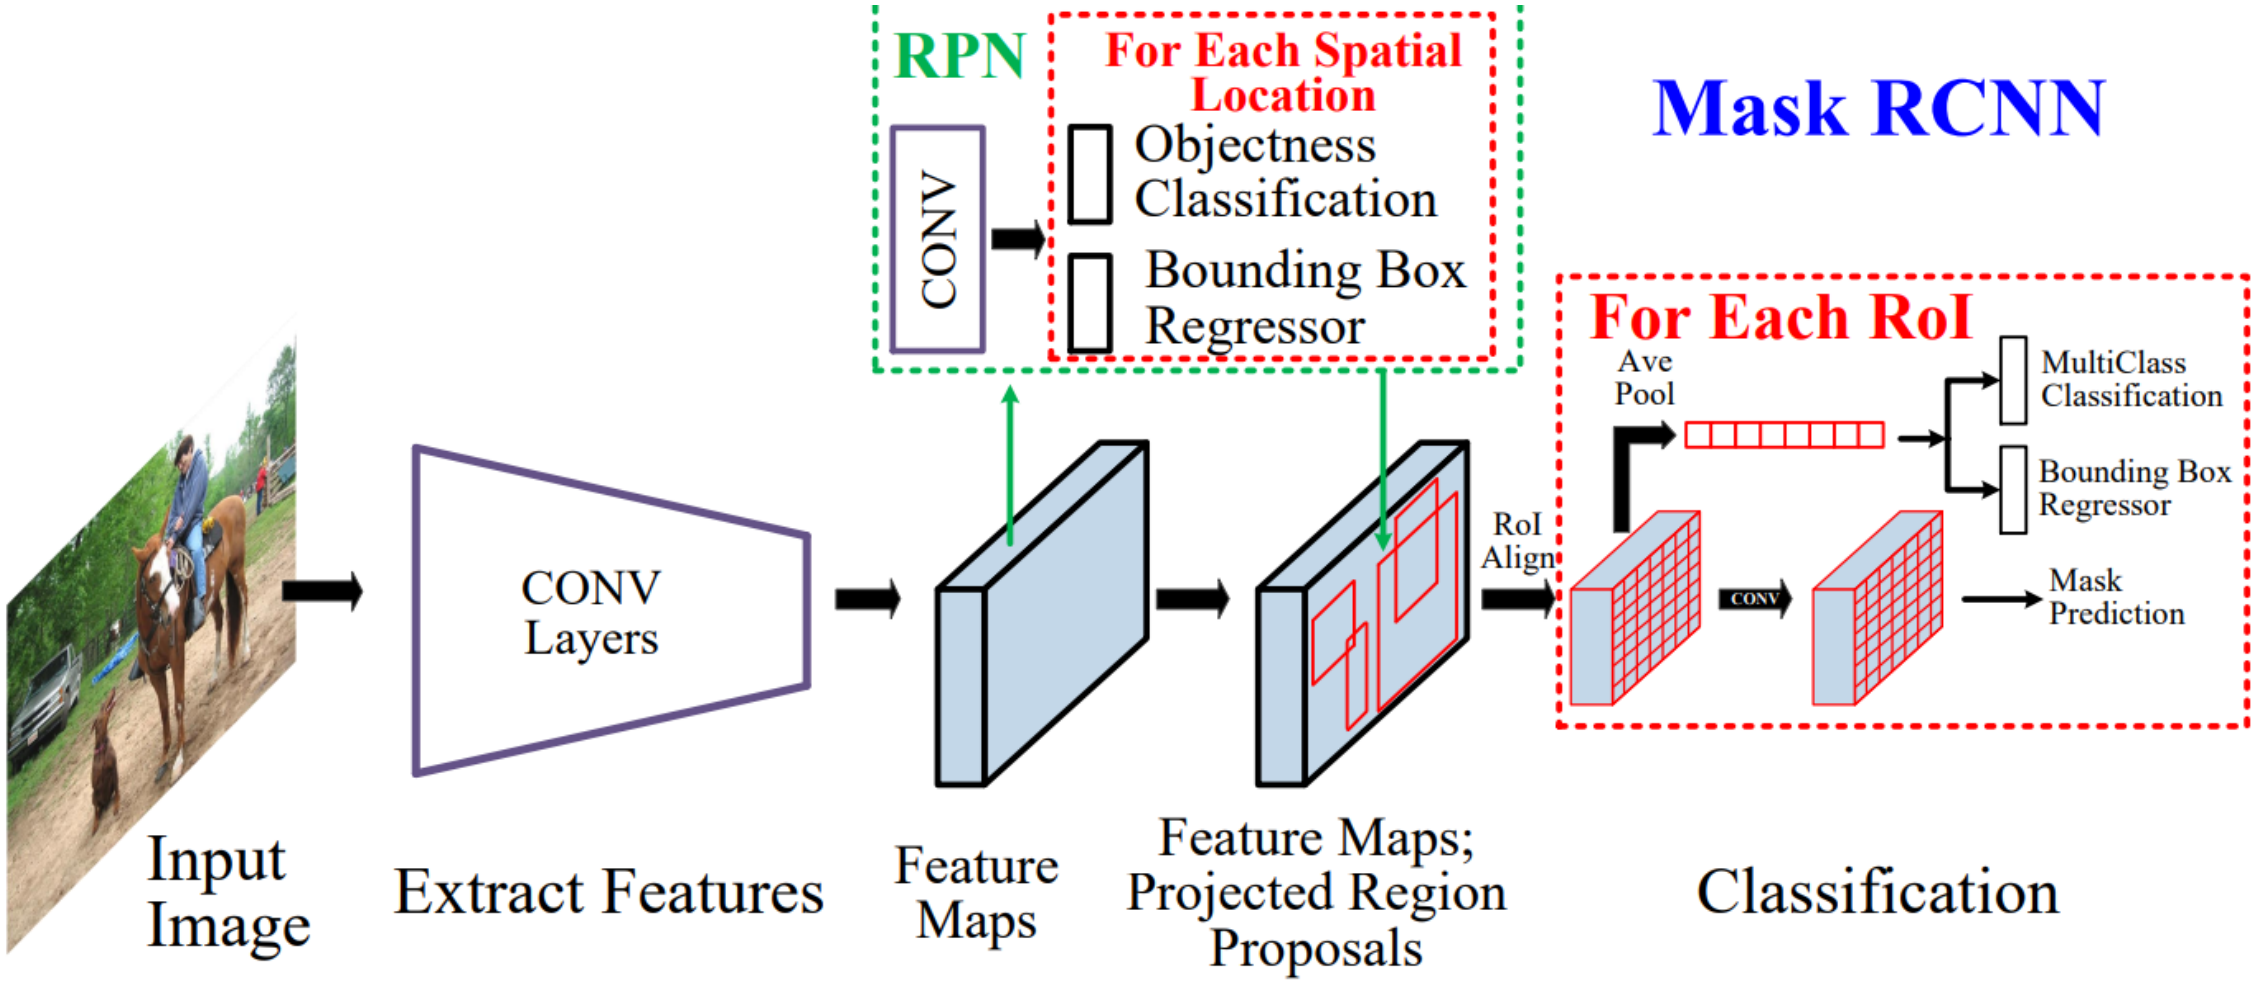



ROI POOL




Fine Tune
using Cross
Entropy and
softmax for
classification

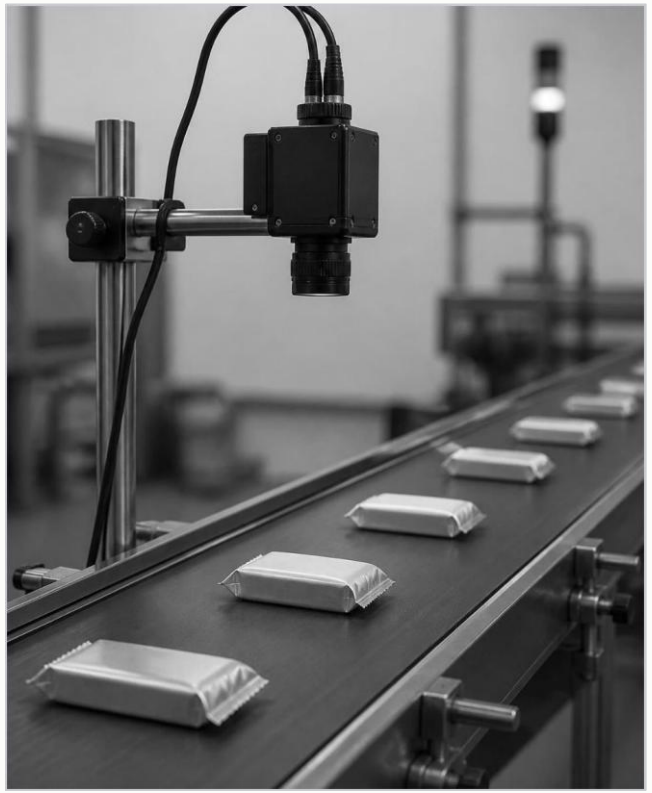

Bounding
Boxes
calculated
from smooth
L1 Loss
(x1,y1,W,H)



задача детектирования, и instance-сегментации одновременно — она предсказывает точные маски (силуэты) объектов внутри bounding box’ов.

ДЕТЕКЦИЯ · YOLO

YOLO: скорость и простота развёртывания

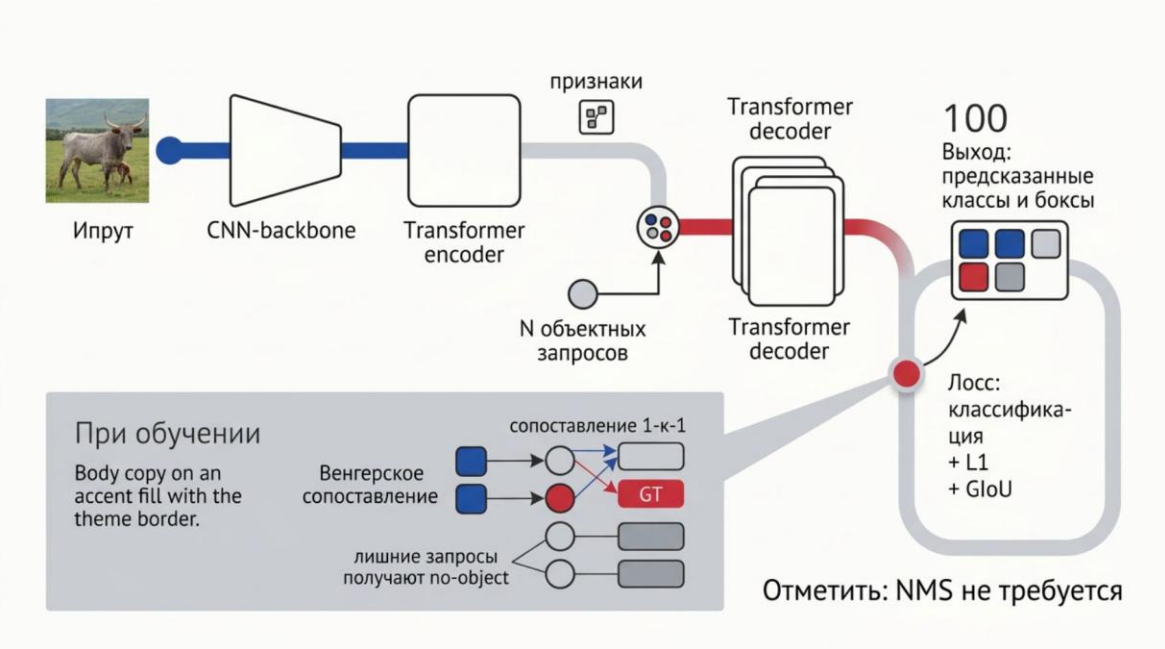


Плотное предсказание на сетке нескольких масштабов, без стадии предложений.

- Якорные версии → anchor-free: YOLOX, YOLOv8, YOLO11.
- End-to-end без NMS: YOLOv10, YOLO26.
- YOLO26 (январь 2026): до 43% быстрее на CPU; COCO 40.9–57.5 mAP при 1.7–11.8 мс на T4 TensorRT.
- Малые и плотные объекты остаются сложным режимом.

ДЕТЕКЦИЯ · SET PREDICTION

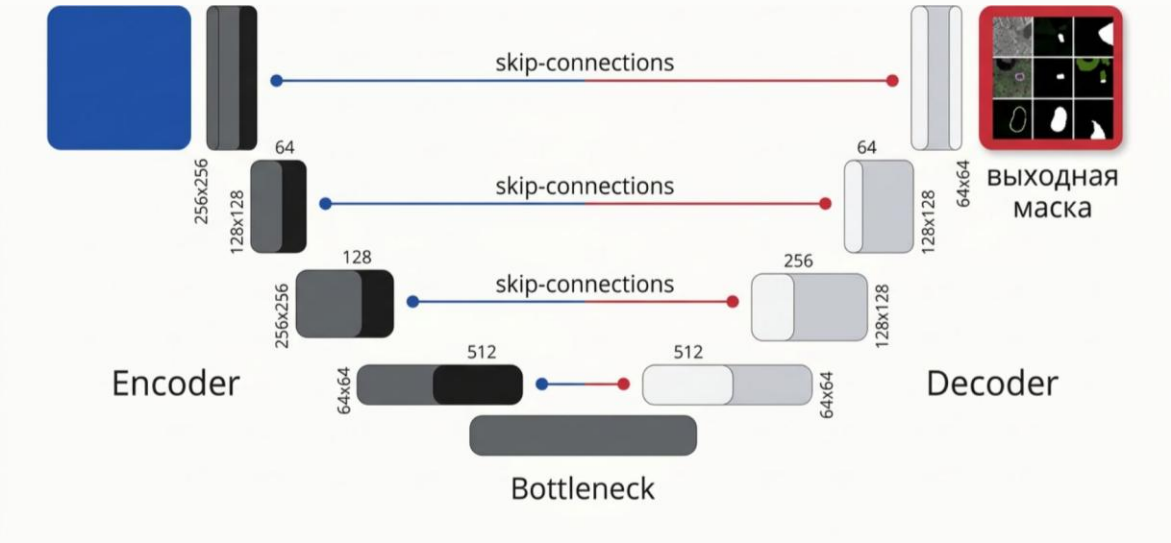
DETR и RT-DETR: детекция без NMS



Один запрос на один объект. Исходный DETR медленно сходится и испытывает трудности с малыми объектами.

Deformable DETR и DINO улучшают обучение. RT-DETR является DETR реального времени, конкурирующим с YOLO.

U-Net и семейство сегментаторов



U-Net++, nnU-Net для медицины, DeepLabv3+, SegFormer.

Mask2Former решает semantic, instance и panoptic одной архитектурой.

Практический baseline: segmentation_models_pytorch с предобученным энкодером.

Авторская схема по Ronneberger et al., U-Net.

МОДЕЛИ · ИНЖЕНЕРНЫЙ ВЫБОР

Как выбрать семейство моделей

Семейство	Скорость	Точность	Малые объекты	Deploy	Выбор
YOLO	Высокая	Сильный баланс	Нужны масштабы	Простой	Real-time, edge
Faster/Mask R-CNN	Ниже	Сильная локализация	FPN, настройка	Сложнее	Baseline, маски
DETR/RT-DETR	Зависит от версии	Set prediction	Улучшены в вариантах	Без NMS	Плотные сцены
U-Net	Зависит от encoder	Dense masks	Skip, разрешение	Обычно простой	Медицина, дефекты, ДЗЗ

Качественные ориентиры, не рейтинг benchmark. Проверять latency и ошибки на собственных данных.

ДАННЫЕ · КООРДИНАТЫ

Формат COCO и его типичные ловушки

COCO

JSON содержит images, categories, annotations.

$$\text{bbox} = [x_{\min}, y_{\min}, w, h]$$

Координаты и размеры в пикселях.

YOLO

$$\text{bbox} = [x_c/W, y_c/H, w/W, h/H]$$

Центр, ширина и высота нормированы на размер изображения.

Путаница форматов координат является одной из главных причин некорректной разметки.

area обозначает площадь маски и определяет small/medium/large. iscrowd=1 не оценивается как обычный экземпляр.

ДАННЫЕ · АУДИТ

Аудит разметки перед обучением

01 **Техническая проверка**

Боксы за границами, нулевая ширина, битые ссылки.

---

02 **Статистическая проверка**

Распределения классов и размеров; редкие режимы.

---

03 **Визуальная проверка**

50–100 случайных изображений с наложенной разметкой.

---

04 **Согласованность**

Правила аннотирования и межразметчиковое согласие задают ориентир точности.

---

05 **Модель-помощник**

FP с высоким score часто выявляют пропуски разметки.

ДАННЫЕ · СЛОЖНЫЕ РЕЖИМЫ

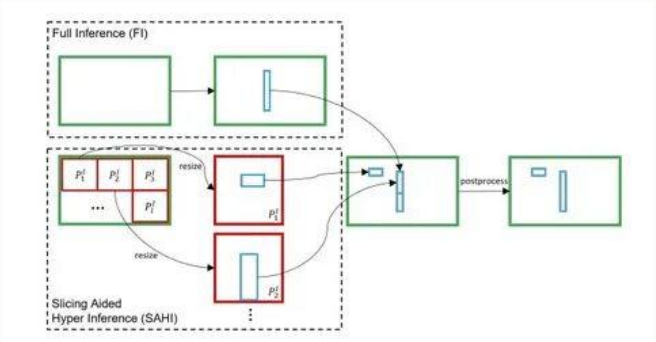
Малые объекты и редкие классы

Малые объекты

$$\text{area} < 32^2 \quad \text{(COCO)}$$

Увеличить разрешение; использовать тайлинг SAHI, уровень P2 и copy-paste.

Контролировать потерю контекста и дублирование на границах тайлов.



Редкие классы

Repeat factor sampling из LVIS; focal loss; стратификация редких классов в val и test.

Отдельно проверять полноту разметки и устойчивость метрики.

Отчёт по каждому классу обязателен: средний mAP скрывает провалы.

ДАННЫЕ · АУГМЕНТАЦИИ

Аугментации должны отражать реальные условия

Геометрия

Преобразовать изображение, боксы и маски синхронно. Проверять корректность обрезки.

Композиция

Mosaic, MixUp и Copy-Paste меняют содержание сцены и соответствующие метки.

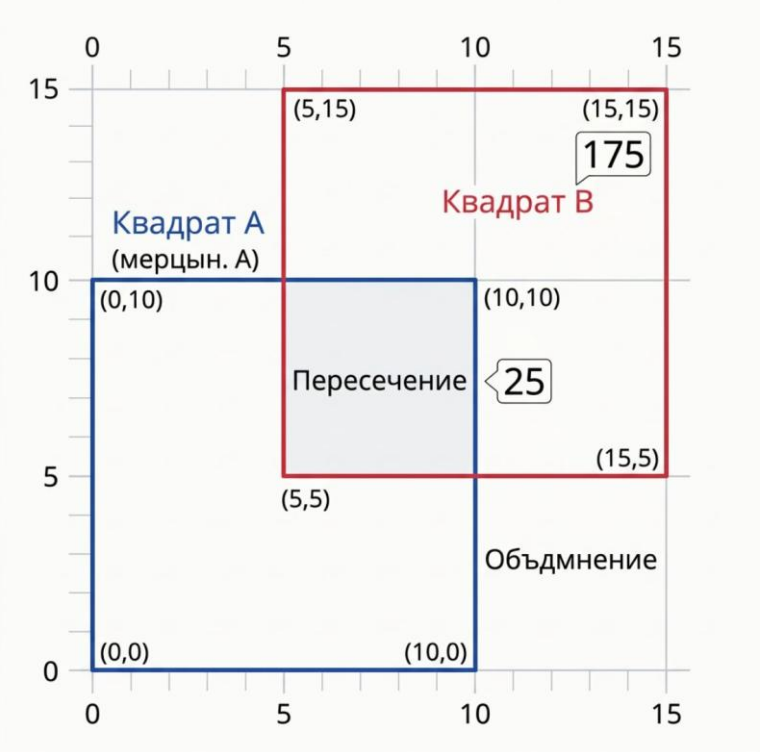
Семантика

Флип запрещён, если меняет смысл: стрелки знаков, текст, левая и правая сторона в медицине.

В YOLO mosaic отключают на последних эпохах: close_mosaic.

Аугментация должна моделировать вариативность deployment, а не создавать неверные примеры.

IoU и Dice: связь и числовой пример



$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{25}{175} \approx 0.143$$

$$\text{Dice} = \frac{2\,|A \cap B|}{|A| + |B|}$$

$$\text{Dice} = \frac{2\,\text{IoU}}{1 + \text{IoU}}$$

Dice ≥ IoU. При IoU = 0.5 получаем Dice ≈ 0.667.

Сдвиг на полстороны даёт очень низкий IoU.

МЕТРИКИ · DETECTION AP

Precision, Recall, AP и mAP@[.5:.95]

$$P = \frac{TP}{TP + FP}$$

TP требует верного класса и достаточного IoU с ещё не сопоставленным GT. Обход по убыванию score.

$$R = \frac{TP}{TP + FN}$$

COCO AP интерполируется по 101 точке recall; mAP усредняется по классам и IoU 0.50:0.05:0.95.

AP50 = 0.82

Объекты находятся при мягком пороге локализации.

AP = 0.48

При строгих порогах качество существенно ниже.

AP_S = 0.12

Малые объекты являются главной проблемой.

AP75 проверяет строгую локализацию; AP_S/M/L разделяют размеры. Для mAP сохранять предсказания со score около 0.001.

Типология ошибок по TIDE

Ошибка	Определение	Вероятная причина	Что проверять
Classification	Бокс верен, класс неверен	Сходные классы	Онтологию, примеры
Localization	Класс верен, бокс неточен	Границы, масштаб	Разметку, разрешение
Both	Класс и бокс неверны	Сложная сцена	Срезы данных
Duplicate	Повторная детекция GT	Постобработка	NMS, matching
Background	Детекция без объекта	Фоновые паттерны	Негативы, пропуски GT
Missed	Объект не найден	Размер, окклюзия	Recall, редкие классы

Отчёт включает AP по размерам и классам, разбивку ошибок и галерею худших примеров.

ТЕМА 3. FOUNDATION MODELS ДЛЯ СЕГМЕНТАЦИИ И OPEN-VOCABULARY

Подсказки, семантика и контролируемая предразметка

SAM · ЗАДАЧА И ДАННЫЕ

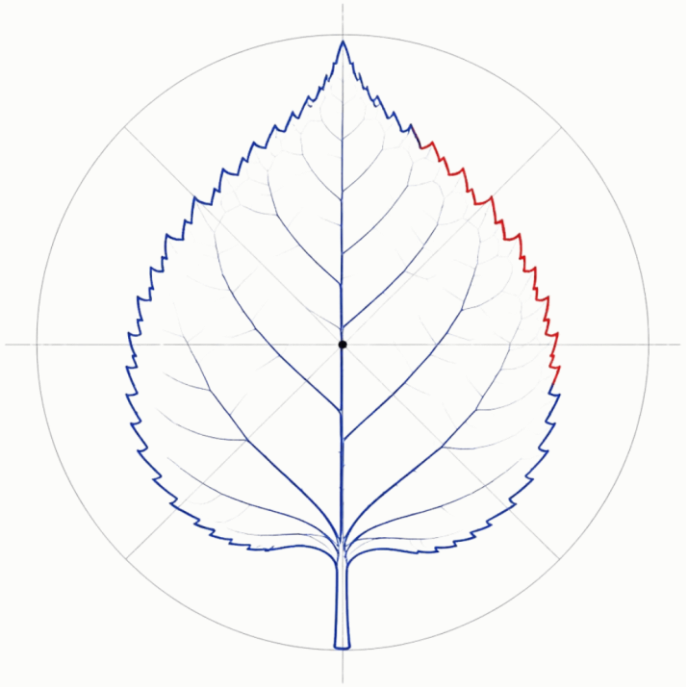
SAM: промптируемая сегментация и data engine

Точка, бокс или маска задают объект; SAM возвращает соответствующую маску.

11 млн

изображений в SA-1B; более 1.1 млрд масок.

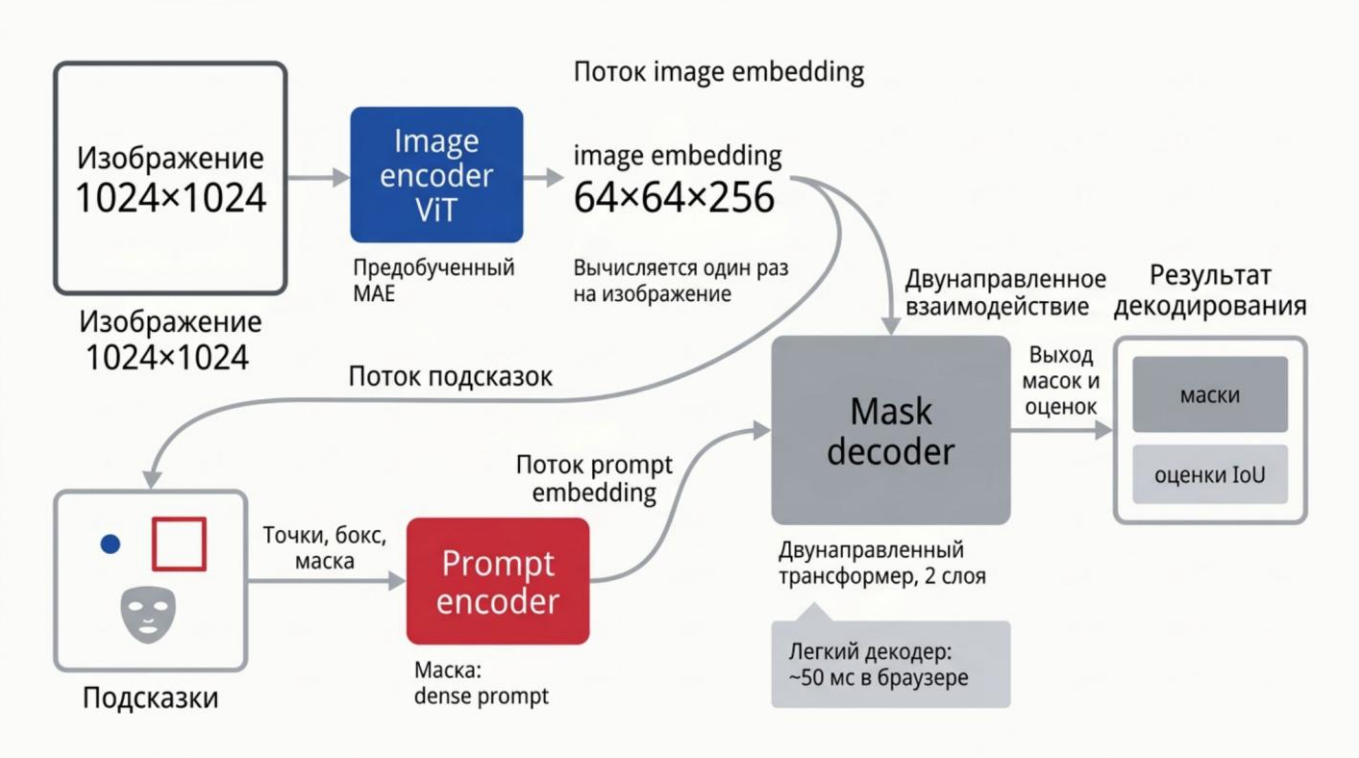
1. Ручная разметка с моделью
2. Полуавтоматическая разметка
3. Полностью автоматическая разметка



Учебная иллюстрация prompt; не фактический вывод SAM. Kirillov et al., 2023.

SAM · АРХИТЕКТУРА

Архитектура SAM: три компонента



Дорогой энкодер считается один раз; новые подсказки используют кеш признаков.

Авторская схема по Kirillov et al., 2023. Время декодера не равно полной latency обработки изображения.

SAM · ВЫБОР ПОДСКАЗКИ

Неоднозначность подсказки и выбор prompt

Одна точка

Точка на рубашке может означать рубашку, человека или пуговицу.

Поэтому выдаются 3 маски с предсказанным IoU.

Бокс

Наиболее стабильный prompt задаёт пространственные границы объекта.

Отрицательные точки помогают исключить соседние области.

Segment everything

Сетка 32×32 точек; генерация кандидатов, фильтрация и NMS.

Покрытие сцены не означает знание классов.

Предсказанный IoU ранжирует кандидатов, но не заменяет контроль качества.

SAM · ГРАНИЦЫ ПРИМЕНИМОСТИ

Ограничения SAM

Семантика

Маска не содержит класса. Для назначения имени объекта нужен другой компонент.

Границы

Тонкие структуры могут быть грубыми; прозрачные объекты остаются сложными.

Домен

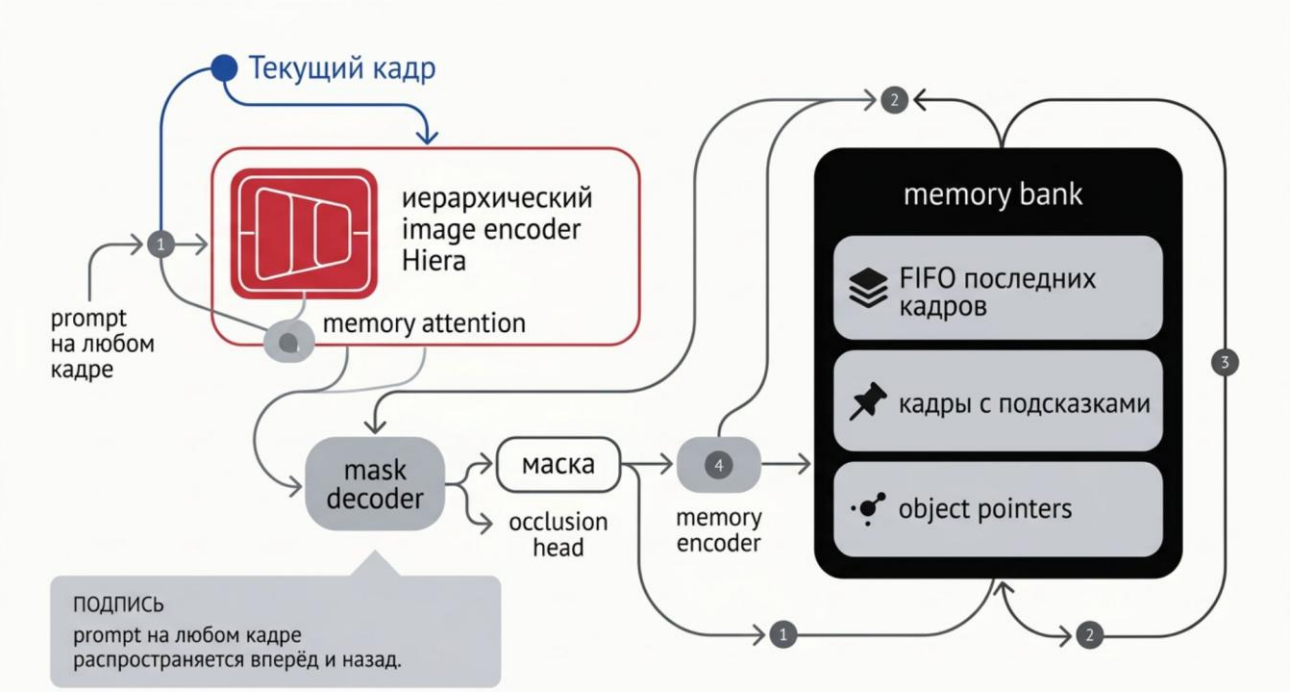
Качество снижается в медицине, микроскопии и ИК. Zero-shot требует проверки.

Ресурсы

Тяжёлый энкодер: ViT-H около 632 млн параметров.

Универсальность предобучения не гарантирует надёжности в конкретном домене.

SAM 2: изображения и видео



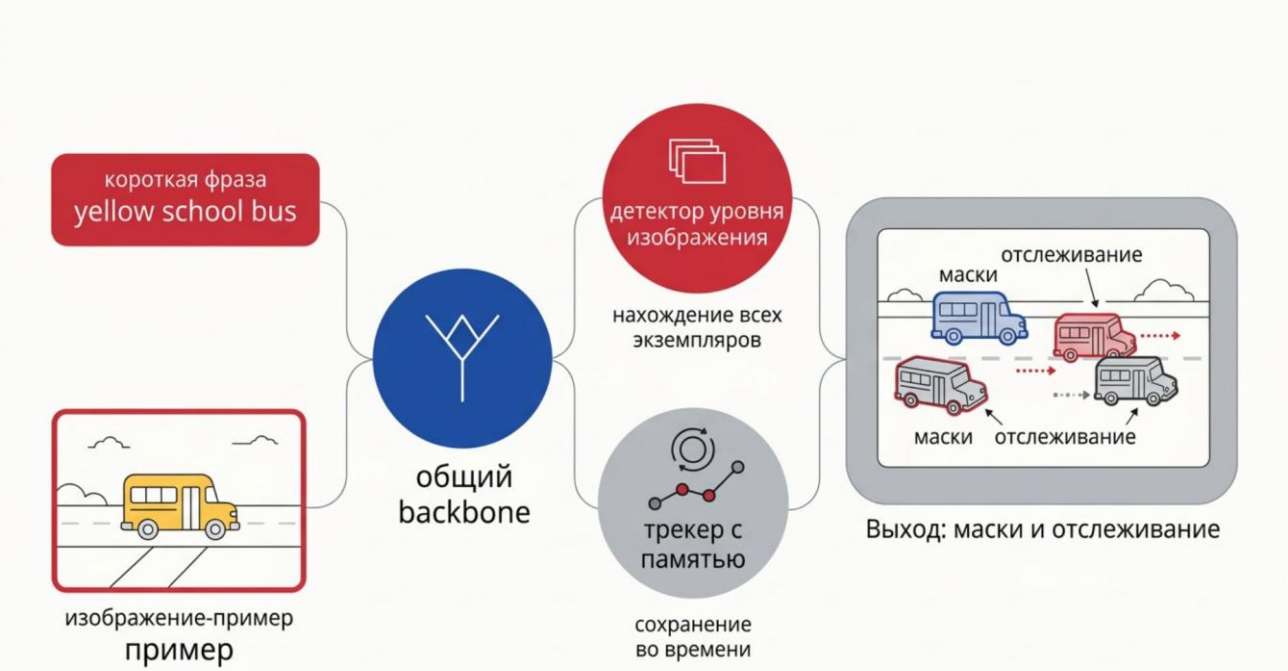
Изображение рассматривается как видео из одного кадра. Occlusion head учитывает исчезновение и возвращение объекта.

Обучение на SA-V. Память связывает сегментацию разных кадров.

Авторская схема по Ravi et al., SAM 2.

SAM 3 · КОНЦЕПТ

SAM 3: сегментация по концепту



Короткая фраза или образец-пример задают концепт. Модель находит, сегментирует и отслеживает все экземпляры.

Общий backbone для детектора и трекера связывает сегментацию с open-vocabulary детекцией.

Схематическое изложение SAM 3 по конспекту.

SAM · ЭФФЕКТИВНОСТЬ

Облегчённые версии SAM

Модель	Подход	Что учитывать
MobileSAM	TinyViT (~5 млн параметров) воспроизводит эмбеддинги SAM	Исходный декодер совместим
EfficientSAM	Masked image pretraining SAMI; дообучение на SA-1B	Проверять качество границ
SAM 2 tiny/small	Меньший иерархический энкодер	Изображения и видео
EfficientViT-SAM, FastSAM	Другие пути к быстрой сегментации	Не считать архитектуры эквивалентными

Дистилляция энкодера сохраняет пространство эмбеддингов, на котором обучен декодер.

SAM · ДОМЕННАЯ АДАПТАЦИЯ

Адаптация SAM к своему домену: от дешёвой к дорогой

01 **Без обучения.** Боксы от детектора, отрицательные точки, постобработка.

02 **Только mask decoder.** Подход MedSAM; эмбеддинги замороженного энкодера кешируются.

03 **Лёгкие головы.** Обучение поверх замороженного энкодера.

04 **Адаптеры и LoRA.** SAM-Adapter, SAMed; ограниченное число обучаемых параметров.

05 **Полный fine-tuning.** Редко оправдан: высокие вычислительные затраты и риск забывания.

OPEN-VOCABULARY · СЕМАНТИКА

Open-vocabulary детекторы дают SAM семантику

OWL-ViT → OWLv2

Двухбашенный энкодер изображение–текст. Запрос задаётся текстом или изображением-примером.

Сходство с запросом определяет семантику найденных объектов.

Grounding DINO

Глубокое слияние изображения и текста.

"scratch . dent . rust ."

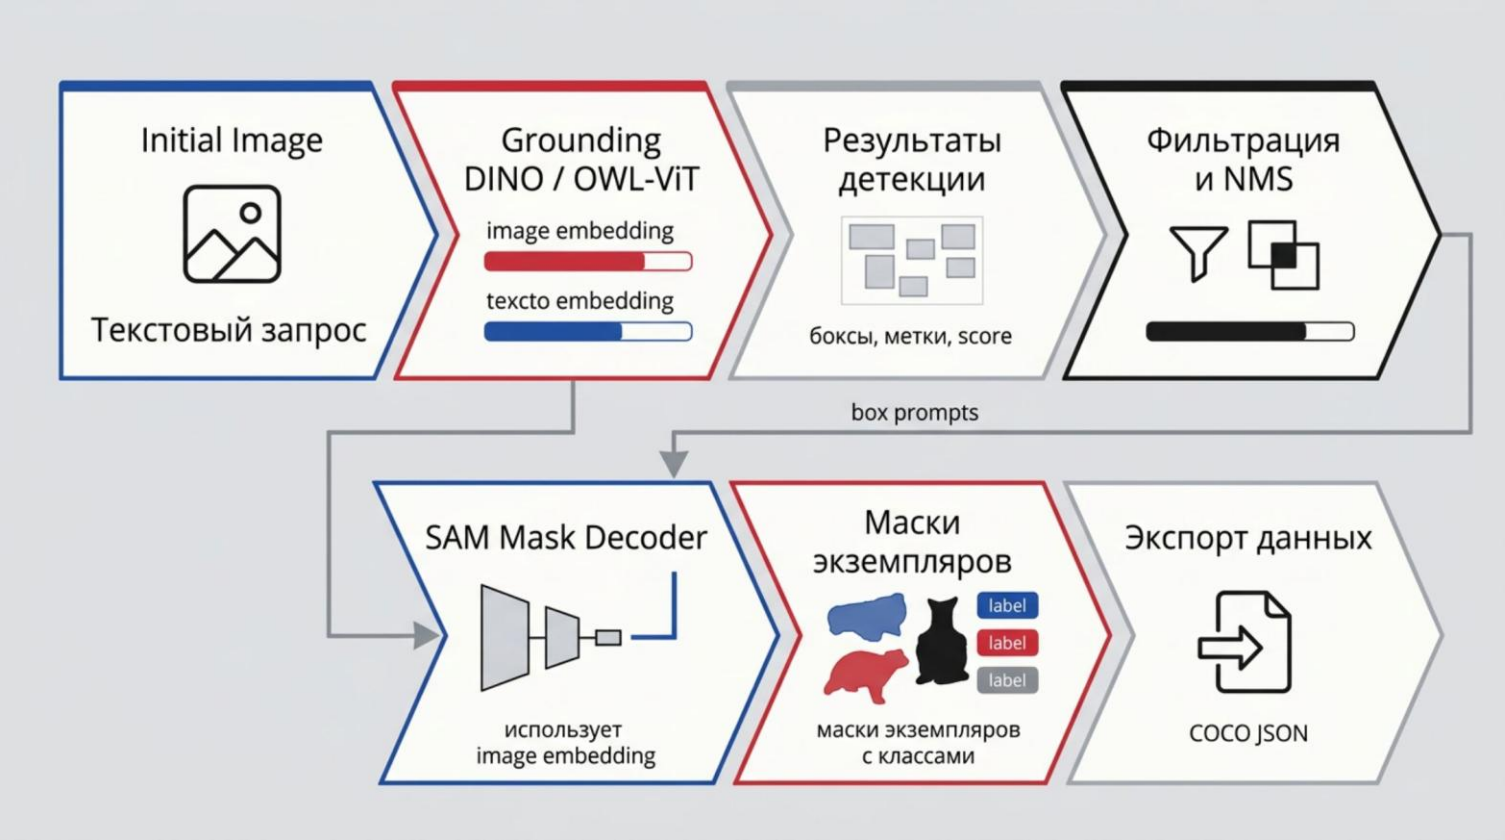
Пороги box_threshold и text_threshold контролируют отбор.

Детектор задаёт класс и бокс; SAM уточняет границу объекта.

Быстрые варианты и смежные решения: YOLO-World, YOLOE, Florence-2, SAM 3.

OPEN-VOCABULARY · GROUNDED-SAM

Конвейер Grounded-SAM



Семантическая ошибка детектора передаётся в итоговую маску и аннотацию.

Авторская схема Grounded-SAM; этап экспорта требует проверки координат, категорий и масок.

OPEN-VOCABULARY · РИСКИ

Типичные проблемы open-vocabulary подхода

Формулировка

«car» и «vehicle» дают разные результаты. Сравнивать запросы на фиксированной validation.

Доменные термины

Неизвестный термин заменять визуальным описанием: «dark pitted spots on metal», либо использовать образец.

Калибровка

Пороги подбирать по validation отдельно для каждого класса.

Наследование ошибок

Пропущенный бокс означает пропущенную маску. SAM не восстанавливает recall детектора.

РАЗМЕТКА · СЦЕНАРИИ

SAM ускоряет разметку: три сценария

1 **Интерактивный**

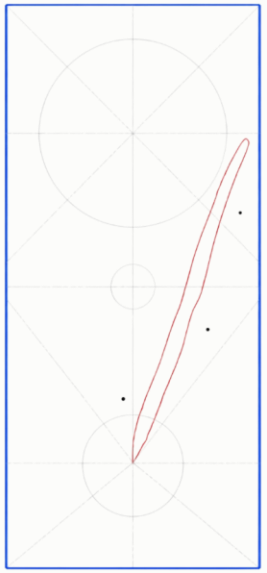
Клики разметчика в CVAT, Label Studio или Roboflow.

2 **Предразметка**

Grounded-SAM или свой детектор; человек проверяет результат.

3 **Model-in-the-loop**

Итеративное улучшение модели и разметки, как в data engine SAM.



Учебный объект для корректирующих подсказок, не вывод SAM.

Контрольная выборка размечается вручную: Mask IoU, Dice, boundary IoU, acceptance rate.

Стоимость правки и риски предразметки

$$T_{image} = T_{accepted} + T_{missed} + T_{edited} + T_{false}$$

Суммарное время включает проверку принятых объектов, добавление пропущенных, исправление масок и удаление ложных объектов.

Выгодность

В примере лекции ускорение около 4 раз. Это результат конкретного сценария, не универсальная гарантия.

При множестве ложных объектов и правке почти каждой маски предразметка невыгодна.

Риски

Automation bias, систематические ошибки SAM, test, размеченный той же моделью.

Фиксировать происхождение каждой аннотации: manual, accepted, edited.

Измерять время и качество на независимой вручную размеченной выборке.

СИНТЕЗ · ИНЖЕНЕРНЫЕ ВЫВОДЫ

Итоги лекции

1. CNN и ViT различаются индуктивными смещениями; выбор смещается к стратегии адаптации
2. Linear probing, частичная разморозка, fine-tuning; LLRD и LP-FT
3. Честное разбиение важнее любой архитектурной находки
4. YOLO, R-CNN, DETR, U-Net: выбор по скорости, точности, размеру объектов
5. mAP без AP по размерам, классам и типологии ошибок ничего не объясняет
6. SAM + open-vocabulary ускоряют разметку, но требуют контроля качества

ПРОВЕРКА ПОНИМАНИЯ

Контрольные вопросы

01 Почему ViT хуже CNN на малых данных, но лучше масштабируется?

02 Чем LP-FT лучше fine-tuning со случайной головой?

03 Три источника утечки для кадров камер видеонаблюдения

04 Зачем DETR венгерское сопоставление?

05 IoU = 0.6: чему равен Dice?

06 AP50 = 0.85, AP75 = 0.40: какой тип ошибок доминирует?

07 Почему SAM выдаёт три маски на одну точку?

08 Как оценить выгодность предразметки SAM?