ЛЕКЦИЯ 3

Foundation models для сегментации и open-vocabulary

SAM, SAM 2, облегчённые версии, open-vocabulary детекция и оценка в задачах разметки



ЛЕКЦИЯ 3

План лекции

01 Мотивация

02 SAM: архитектура и обучение

03 SAM 2: изображения и видео

04 Облегчённые версии и адаптация

05 Open-vocabulary детекция и автоматические prompts

06 Протокол оценки и SAM в разметке

07 Итоги и практика

МОТИВАЦИЯ

Что уже знаем

Supervised-сегментаторы

Лекция 2: U-Net, Mask R-CNN, YOLO-seg обучаются под фиксированный набор классов и требуют тысяч размеченных масок.

Ручная разметка полигоном: десятки секунд на объект, на сложных границах минуты.

Foundation model

Лекция 1: обучается один раз на огромных данных.

Адаптация: linear probing, частичная разморозка, лёгкие головы, PEFT.

МОТИВАЦИЯ

Постановка promptable segmentation

Языковая модель

Prompt (текст) → продолжение

SAM

Prompt (точка, бокс, маска) + изображение → корректная маска (Kirillov et al., 2023)

Даже при неоднозначном prompt хотя бы одна маска представляет разумный объект: точка на рубашке может означать рубашку, человека или пуговицу.

SAM не присваивает классы: семантика добавляется извне.

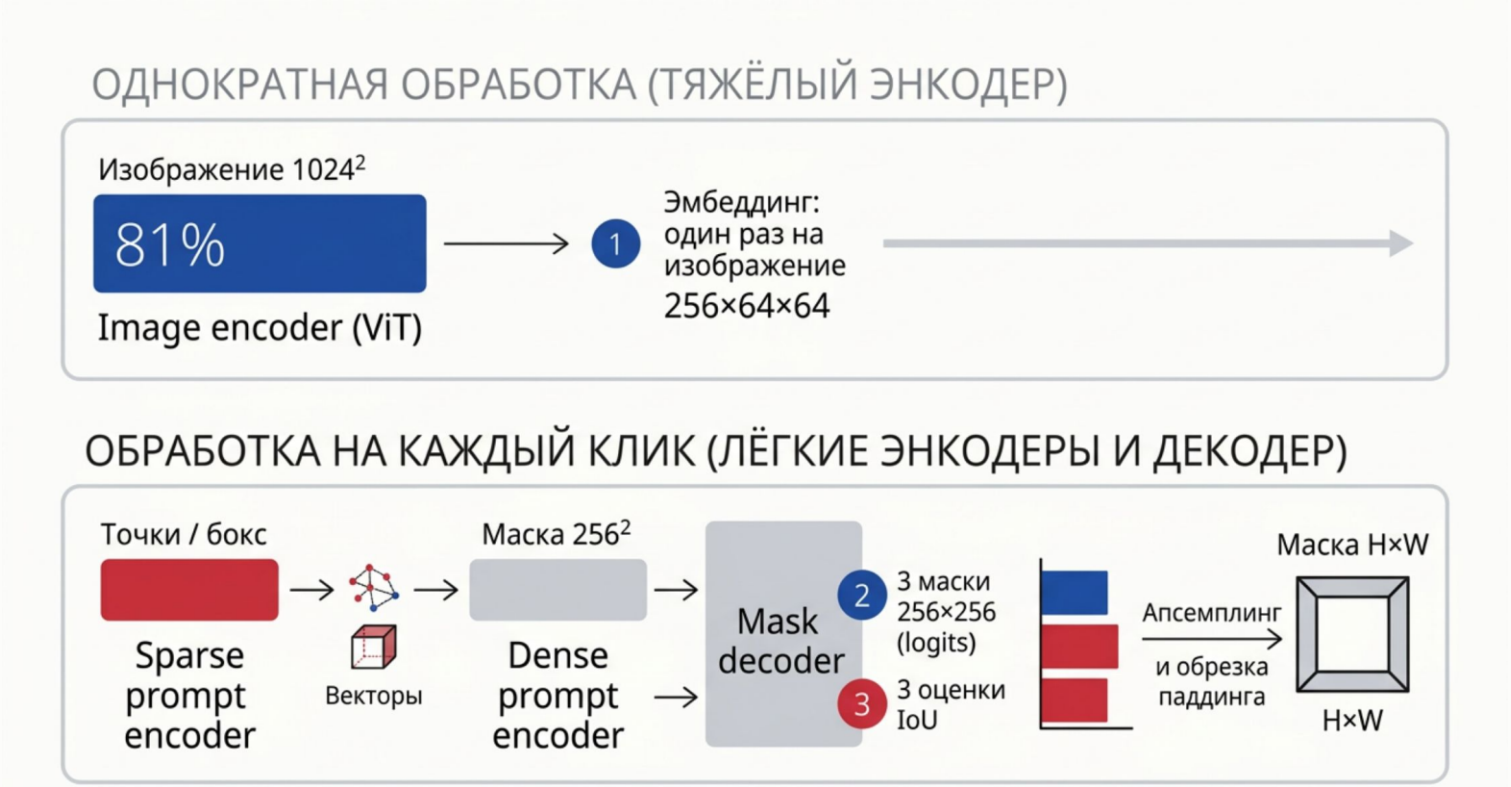


«найти, где объект» + «обвести его»

SAM: АРХИТЕКТУРА И ОБУЧЕНИЕ

SAM

Общая схема SAM



Тяжёлый энкодер один раз; лёгкие prompt encoder и decoder на каждый клик. Около 50 мс в браузере на CPU.

Kirillov et al., 2023

SAM · IMAGE ENCODER

Image encoder

ViT-H/16, около 630 млн параметров; ViT-L и ViT-B как варианты. Предобучение MAE.



$$F \in \mathbb{R}^{256\times64\times64}$$

Kirillov et al., 2023

1 Кеширование

Эмбеддинг считается один раз: около 4 МБ на изображение во float32.

2 Тонкие структуры

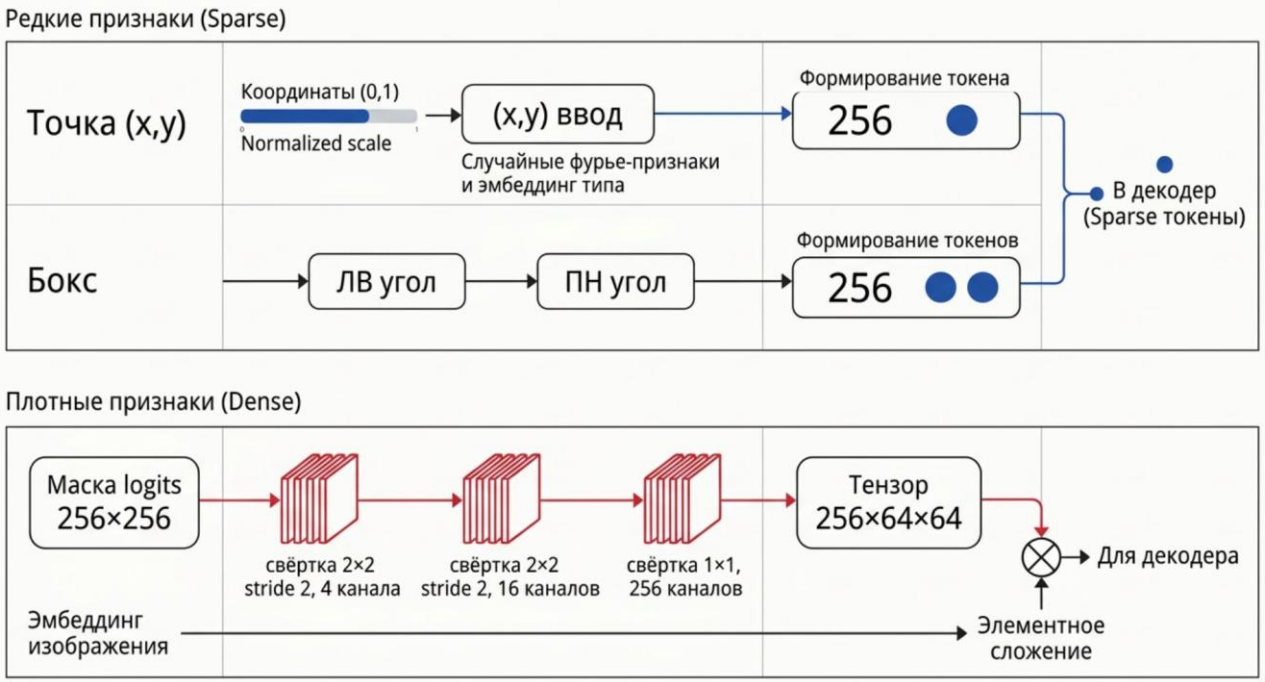
Stride 16: детали мельче ~16 пикселей в масштабе 1024 восстанавливаются только апсемплингом. Слабые структуры: провода, волосы, трещины.

3 Малые объекты

После ресайза до 1024 становятся ещё меньше. Нужен кроп или тайлинг.



Prompt encoder

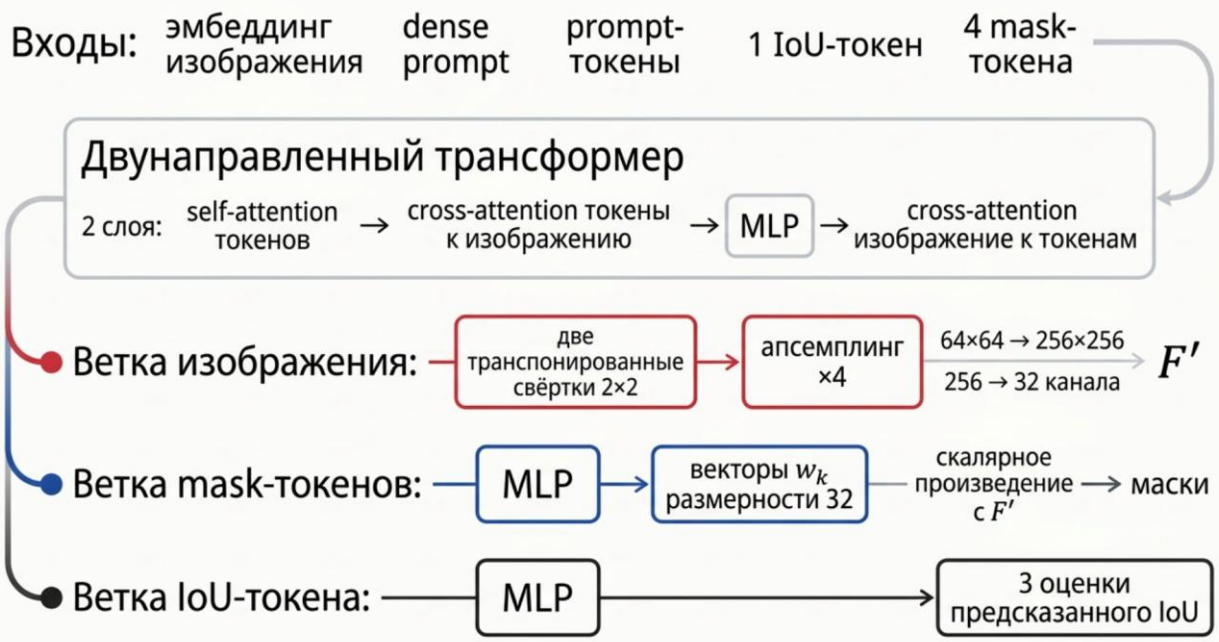


$$PE(p) = [\sin(2\pi Bp); \cos(2\pi Bp)]$$

К PE точки прибавляется эмбеддинг типа: foreground / background.

SAM · MASK DECODER

Mask decoder



$$M_k(i,j) = \quad w_k, F'(i,j) \quad , \qquad w_k \in \mathrm{R}^{32}$$

IoU-токен через MLP даёт 3 числа: предсказанный IoU каждой маски.

SAM · НЕОДНОЗНАЧНОСТЬ

Неоднозначность и многомасочный выход



Градиент идёт только от маски с минимальным лоссом: minimum-over-outputs.

На инференсе: максимум предсказанного IoU или правило задачи, например по площади.

Несколько подсказок: одномасочный выход.

`multimask_output=False`

Почему после второго клика показывают одну маску?

SAM · ОБУЧЕНИЕ

Обучение SAM

Лосс маски: focal loss + Dice loss в отношении 20:1; IoU-голова: MSE.

Симуляция разметки: 11 итераций на маску

01	02	03
Начальный prompt	**8 итераций**	**2 итерации**
Точка или бокс	Точки в области ошибки: FN → положительная; FP → отрицательная	Без новых точек

Data engine SA-1B

11 млн изображений, более 1,1 млрд масок. Assisted-manual → semi-automatic → fully automatic: сетка точек 32×32.

SAM обучен как инструмент разметки: быстрый отклик на клики, а не автономная сегментация.

SAM · PROMPTS

Типы prompts на практике

Prompt	Что даёт	Когда использовать	Типичные ошибки
Одна положительная точка	3 гипотезы разного масштаба	Быстрый выбор объекта человеком	Не тот уровень вложенности, «протекание» на соседние объекты того же цвета
Несколько точек (+/–)	Одна маска	Уточнение, исключение соседей	Отрицательная точка у границы отрезает часть объекта
Бокс	Одна маска, наименее неоднозначно	Есть детектор или боксовая разметка	Слишком тесный бокс; бокс с несколькими объектами
Бокс + отрицательные точки	Одна маска	Перекрывающиеся объекты, фон внутри бокса	—
Маска (logits)	Уточнённая маска	Итеративная коррекция	Бинарная маска вместо logits работает хуже; нужен масштаб 256×256
Сетка точек (automatic)	Все «объекты» изображения	Обзор сцены, поиск кандидатов	Перерасщепление, мусорные фрагменты, нет классов

SAM · API

Код: базовые вызовы SAM

```
from segment_anything import SamPredictor
predictor = SamPredictor(sam)
predictor.set_image(image)
masks, scores, low_res = predictor.predict(point_coords=point, point_labels=positive,
multimask_output=True)
masks, scores, low_res = predictor.predict(box=box, multimask_output=False)
masks, scores, low_res = predictor.predict(box=box, point_coords=negative_point,
point_labels=negative,
    mask_input=low_res, multimask_output=False)
embedding = predictor.get_image_embedding()
```

Одна точка → бокс → итеративное уточнение с отрицательной точкой и low_res logits → кеширование эмбеддинга.

SAM · ОГРАНИЧЕНИЯ

Ограничения SAM

Нет семантики: маска без класса

Тонкие структуры и сложные границы: stride 16 и апсемплинг ×4 дают сглаженные контуры

Доменный сдвиг: КТ, МРТ, УЗИ, микроскопия, ИК и SAR, дефектоскопия

Прозрачные, отражающие, камуфлированные объекты, размытые границы (дым, тень)

Стоимость энкодера ViT-H на edge-устройствах

Чувствительность к prompt: смещение точки на несколько пикселей может сменить уровень вложенности

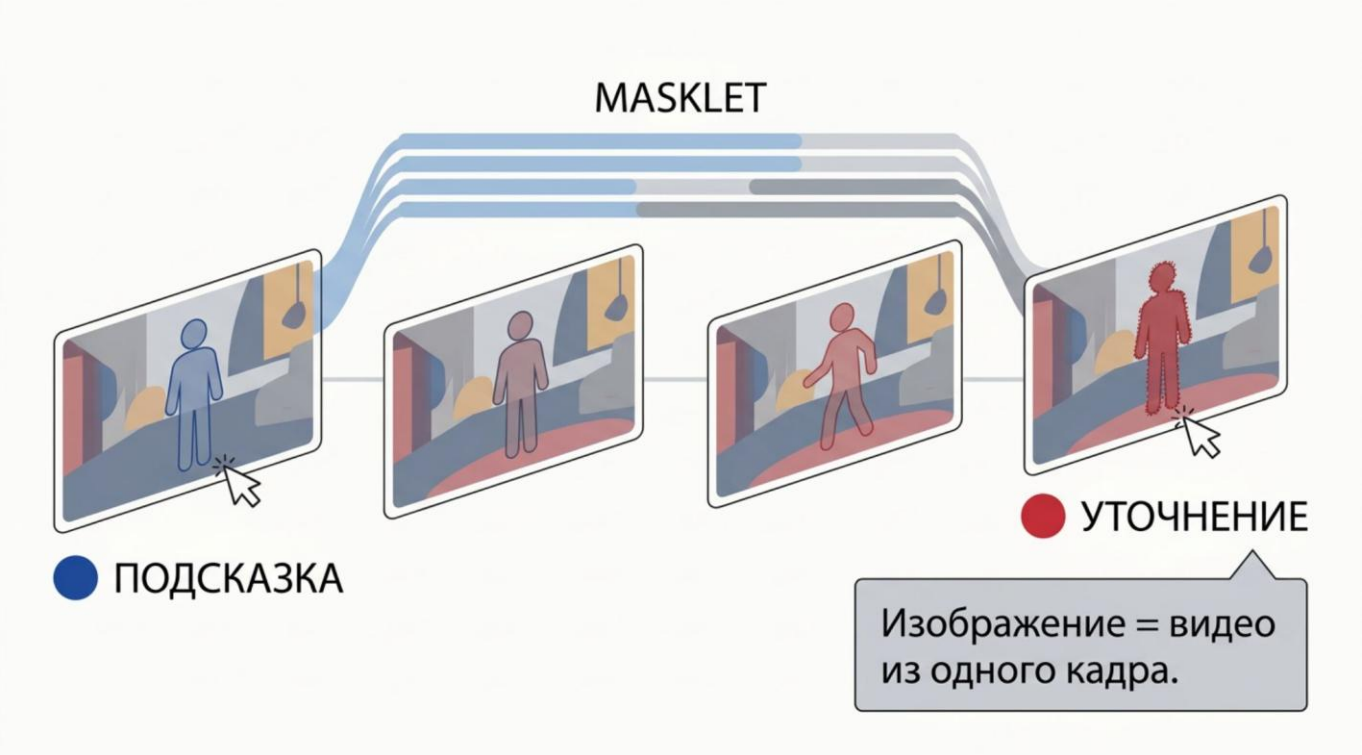


SAM 2: ИЗОБРАЖЕНИЯ И ВИДЕО

SAM 2

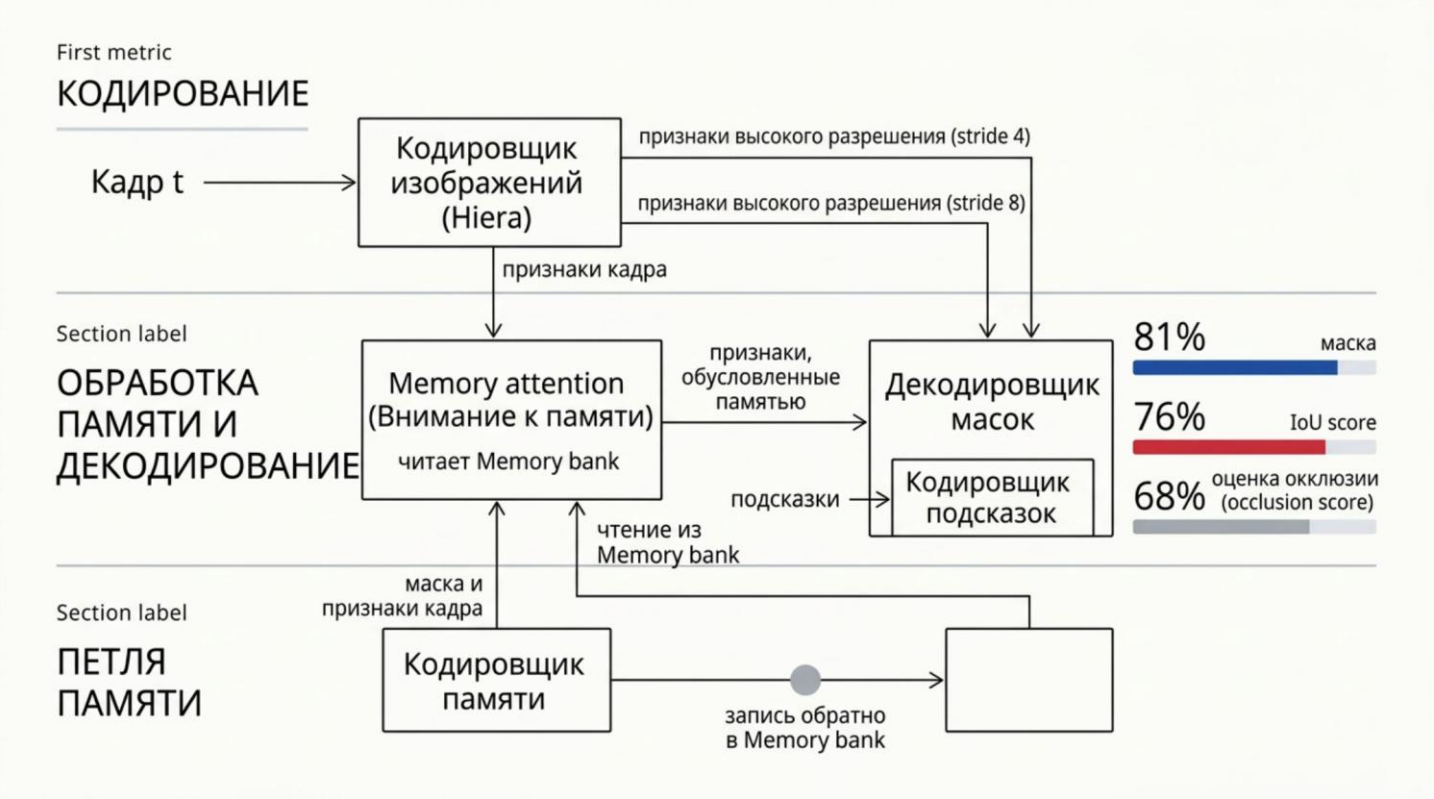
Постановка SAM 2

SAM 2 (Ravi et al., 2024) решает promptable visual segmentation в видео: подсказка на любом кадре, модель строит masklet — пространственно-временную маску объекта на всех кадрах — и принимает уточнения на любых других кадрах. Изображение рассматривается как видео из одного кадра.



SAM 2 · АРХИТЕКТУРА

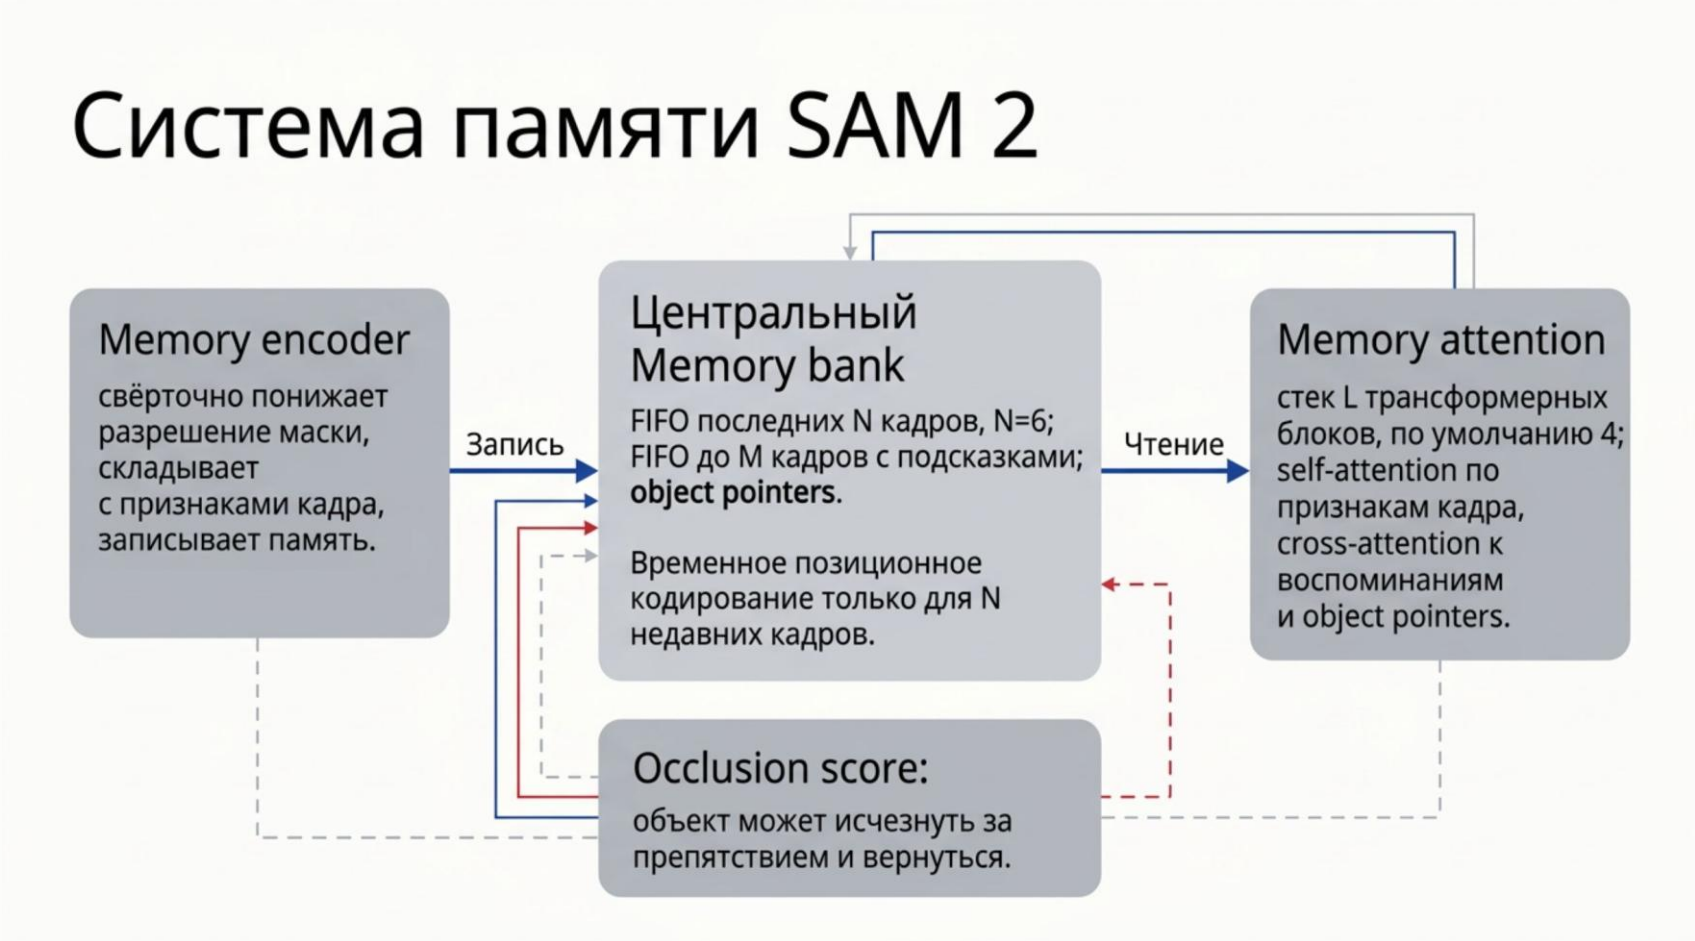
Архитектура SAM 2



SAM 2.1: tiny 38,9 млн; small 46 млн; base+ 80,8 млн; large 224,4 млн параметров.

Ravi et al., 2024

Компоненты памяти SAM 2



SAM 2 · ОБУЧЕНИЕ

Данные и обучение SAM 2

50,9 тыс.
видео SA-V

642,6 тыс.
masklet-ов

35,5 млн
масок

10 млн ручные

Совместное обучение на SA-1B и видео; симуляция подсказок на случайных кадрах.

Примерно в 3 раза меньше взаимодействий в видео; на изображениях точнее и примерно в 6 раз быстрее SAM.

SAM 2 · ПРАКТИКА

Сценарий работы с видео

01 **init_state**

Кадры загружаются.

---

02 **Подсказка на кадре t_0**

Точки, бокс или маска для объекта с obj_id.

---

03 **propagate_in_video**

Распространение вперёд и назад с использованием памяти.

---

04 **Клик на кадре с ошибкой**

Модель пересчитывает кадр и последующие.

---

05 **Несколько объектов**

Разные obj_id, независимое отслеживание.

SAM 2 · СБОИ

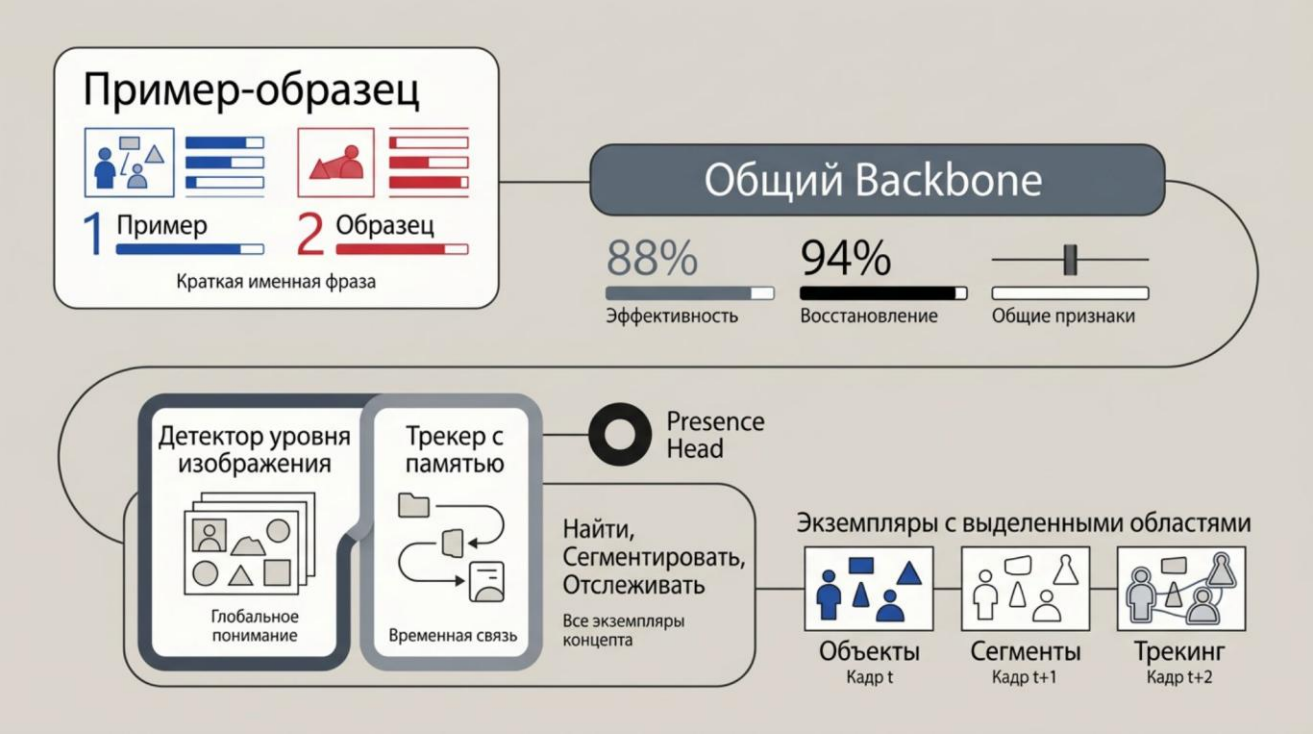
Типичные сбои в видео и что с ними делать

Сбой	Причина	Действие
Дрейф на соседний похожий объект	Похожий вид, перекрытие	Отрицательный клик; подсказка сразу после перекрытия
Потеря после длительной окклюзии	Воспоминания вытеснены из FIFO	Повторная подсказка после возвращения объекта
«Мерцание» границ	Покадровая неопределённость	Временное сглаживание, морфология, проверка IoU между соседними кадрами
Резкая смена масштаба или ракурса	Память устарела	Дополнительная подсказка; хранить подсказанные кадры
Склейка планов	Память несовместима	Резать видео на планы до разметки

РАЗВИТИЕ ЛИНИИ

Развитие линии: SAM 3

SAM 3 (Meta, 2025) добавляет promptable concept segmentation.



Внутренняя интеграция open-vocabulary детекции и SAM 2.

ОБЛЕГЧЁННЫЕ ВЕРСИИ И АДАПТАЦИЯ

MOBILESAM

MobileSAM: дистилляция энкодера

Учитель · ViT-H

Эмбеддинги учителя предвычисляются.

Студент · TinyViT

5,78 млн параметров. После дистилляции студент соединяется с исходными prompt encoder и decoder SAM.

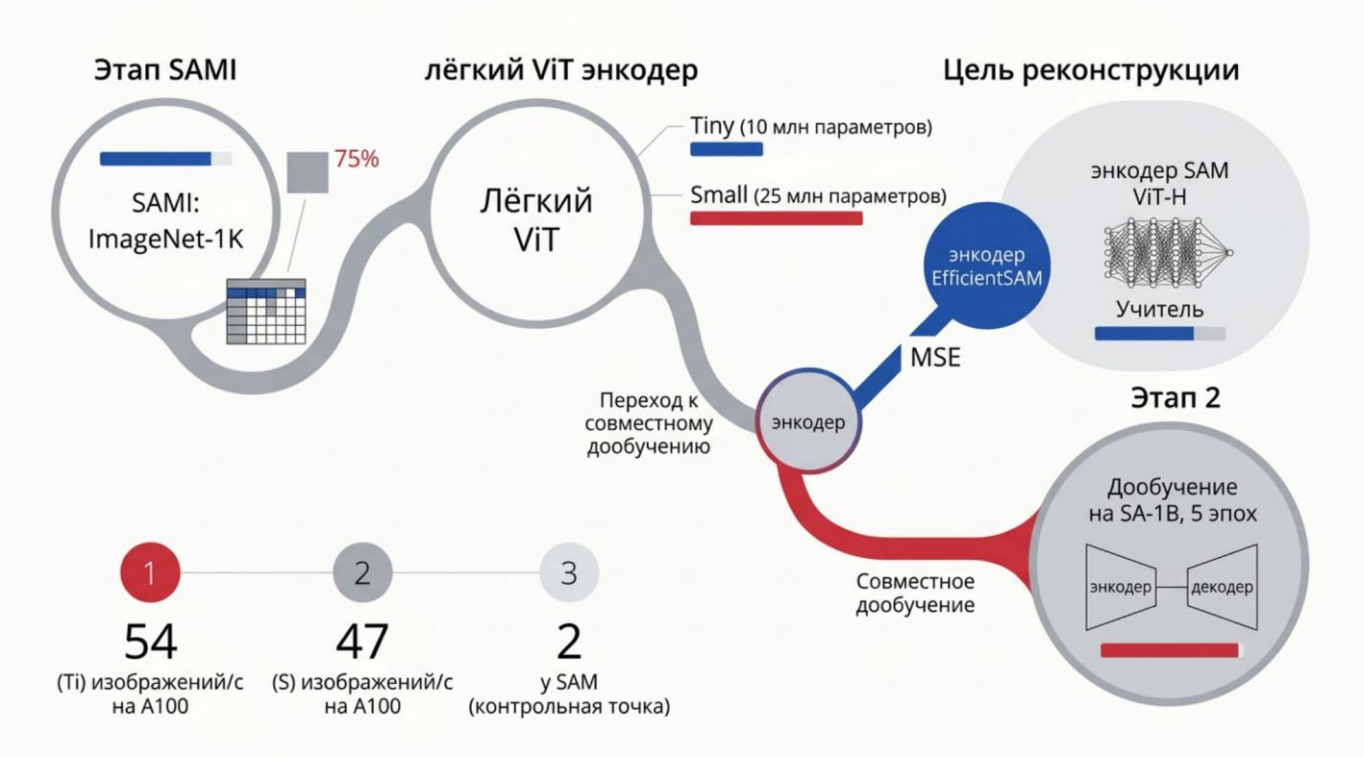
Decoupled distillation: без участия декодера и масок

$$L_{\text{distill}} = \frac{1}{|\Omega|} \sum_{(i,j)\in\Omega} \left\| F^{S}_{:,i,j}(x) - F^{T}_{:,i,j}(x) \right\|_2^2$$

Всё — 9,66 млн параметров; около 8 мс энкодер + 4 мс декодер. 1% SA-1B, 8 эпох, один GPU, меньше суток. Тот же SamPredictor, модель `vit_t`.

EFFICIENTSAM

EfficientSAM: SAMI-предобучение



Отличие от MobileSAM: признаки SAM как цель предобучения, затем дообучается всё.

ОБЛЕГЧЁННЫЕ ВЕРСИИ

Сравнение облегчённых вариантов

Модель	Энкодер	Как получена	Декодер	Когда выбрать
SAM ViT-H/L/B	ViT, MAE	Обучение на SA-1B	Исходный	Эталон качества, офлайн-предразметка на GPU
MobileSAM	TinyViT 5,78 млн	Дистилляция эмбеддингов	Исходный SAM	CPU/edge, интерактивная разметка в браузере, обучение голов в Colab
EfficientSAM	ViT-T 10 млн / ViT-S 25 млн	SAMI + fine-tuning	Дообученный	Лучше качество при малом размере
SAM 2.1 tiny/small	Hiera (38,9 / 46 млн)	SA-1B + SA-V	SAM 2	Видео, трекинг, лучшие границы

Сначала измерить на своих данных качество масок при одинаковых prompts и время энкодера на целевом устройстве.

АДАПТАЦИЯ

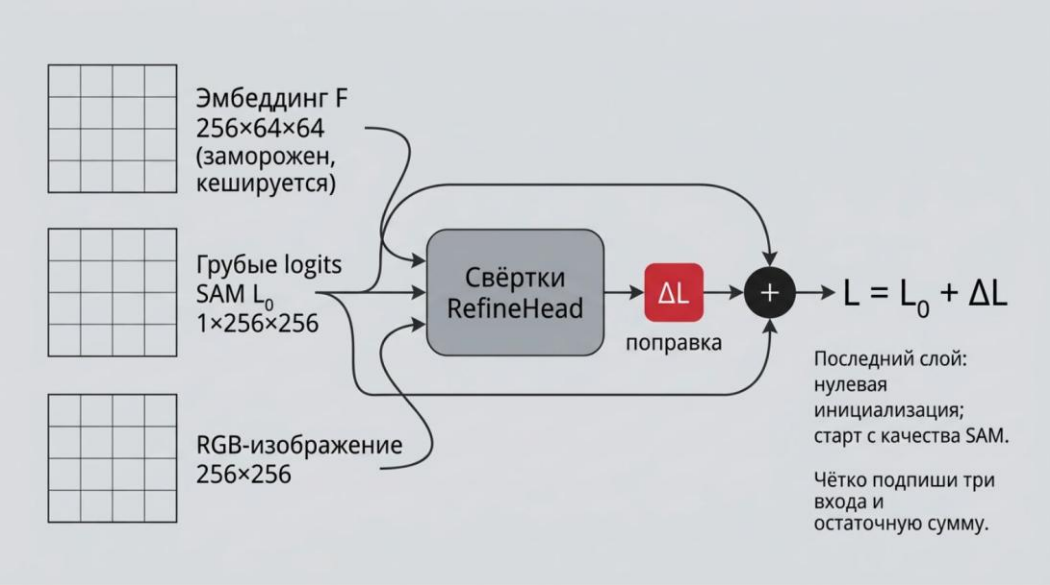
Стратегии адаптации к домену

Уровень	Что обучается	Данные	
	0. Prompt engineering	Ничего	20–50 изображений для валидации
1. Лёгкая голова на замороженном энкодере	0,1–2 млн параметров	Сотни масок	
2. Дообучение mask decoder	≈4 млн параметров	Сотни–тысячи масок	
3. Адаптеры / LoRA в энкодере	1–5% параметров	Тысячи масок	
4. Полный fine-tuning	Всё	Много	

Виды голов: mask refinement, классификация маски (masked average pooling), семантическая, оценки качества.

АДАПТАЦИЯ · REFINEHEAD

Mask refinement head на замороженном MobileSAM



$$L = L_0 + \Delta L$$

$$L = \mathrm{BCE}(L, Y) + \mathrm{Dice}(\sigma(L), Y) + \lambda\,\mathrm{BCE}_{\partial}(L, Y), \quad \lambda \approx 1$$

BCE_{∂} : BCE по полосе 3–5 пикселей вокруг границы эталона Y.

АДАПТАЦИЯ · ЭКСПЕРИМЕНТ

Обучение RefineHead и абляции

Обучение

Кеш: эмбеддинг, RGB-сетка, low_res logits по prompts: бокс с шумом, точки.

Только RefineHead: AdamW, lr 10^{-3}, cosine, 20–50 эпох. Энкодер и декодер заморожены.

Абляции

- MobileSAM zero-shot; SAM ViT-H zero-shot
- Без RGB; без эмбеддинга; без граничного лосса
- Дообучение декодера; supervised baseline

Без утечек: маски одного изображения, кадры одного видео, тайлы одного снимка в одной части выборки.

OPEN-VOCABULARY ДЕТЕКЦИЯ И АВТОМАТИЧЕСКИЕ PROMPTS

OPEN-VOCABULARY

Проблема: SAM знает «где», но не «что»

Закрытый детектор (YOLO, Faster R-CNN) знает только классы обучения.

Текст	Боксы	SAM
Произвольный запрос	**Локализация + метки**	**Сегментация**
Open-vocabulary детектор	Готовые box prompts	Маски с семантическими метками

Опора: совместное пространство изображение–текст, как в CLIP (будет в следующей лекции).
Класс определяется близостью векторов.

OPEN-VOCABULARY · OWL

OWL-ViT и OWLv2

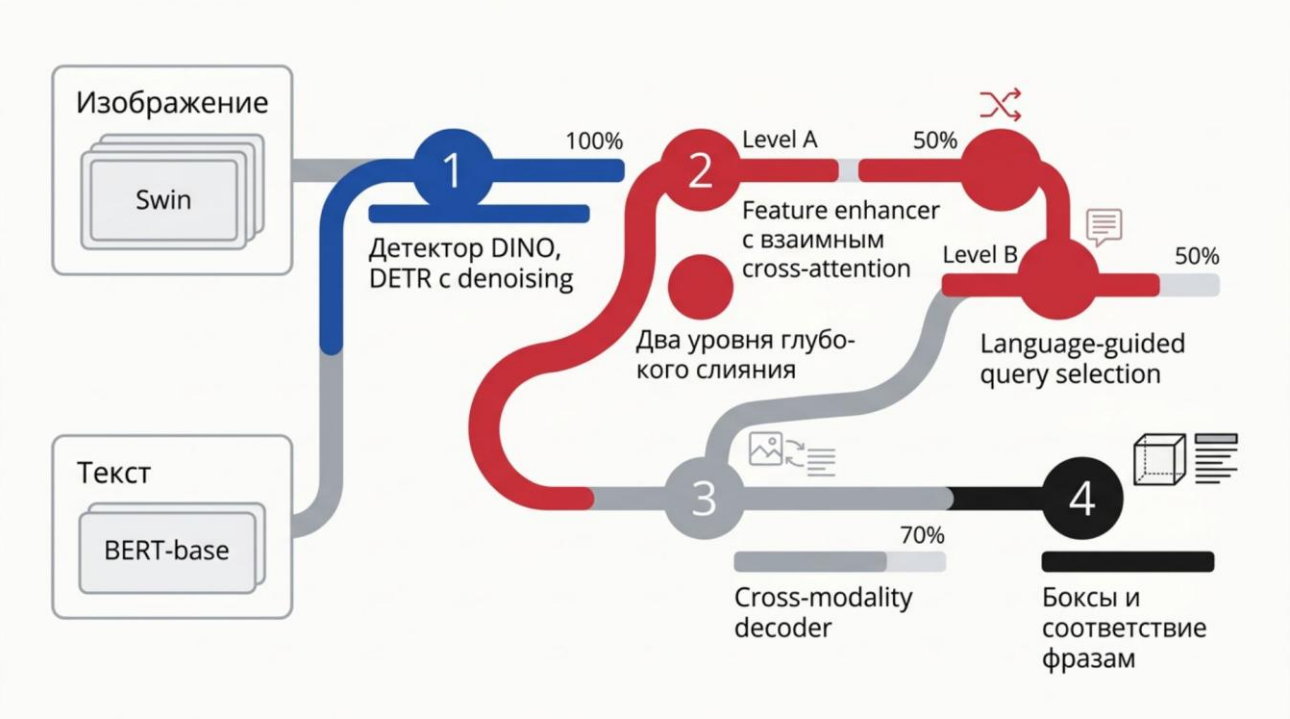


OWLv2: self-training на более чем 1 млрд веб-пар.

AP на редких классах LVIS: 31,2% → 44,6%.

OPEN-VOCABULARY · GROUNDING

Grounding DINO



Обучение на детекции, grounding и псевдоразмеченных подписях; zero-shot 52,5 AP на COCO.

Фразы через точку: `"scratch . dent . rust ."`

Два порога: `box_threshold` и `text_threshold`.

OPEN-VOCABULARY · СРАВНЕНИЕ

OWL-ViT / OWLv2 и Grounding DINO

Свойство	OWL-ViT / OWLv2	Grounding DINO
Слияние изображения и текста	Позднее (скалярное произведение)	Раннее и глубокое (энкодер и декодер)
Запрос изображением-примером	Да	Нет (в базовой версии)
Сложные фразы и отношения	Слабее	Сильнее
Скорость	Обычно выше: текст можно кешировать	Обычно ниже: текст в каждом слое
Типичный порог	Score по классу	Порог объекта + text_threshold

Автоматические prompts

$$b = (x_1 + \varepsilon_1 w,\ y_1 + \varepsilon_2 h,\ x_2 + \varepsilon_3 w,\ y_2 + \varepsilon_4 h)$$

Оракульный режим

Для оценки: бокс из маски с шумом.

Точка: максимум distance transform, не центр масс.

Клики по наибольшей компоненте ошибки $E = \mathrm{FN} \cup \mathrm{FP}$.

Эксплуатационный режим

Боксы от YOLO26, RT-DETR или open-vocabulary детектора.

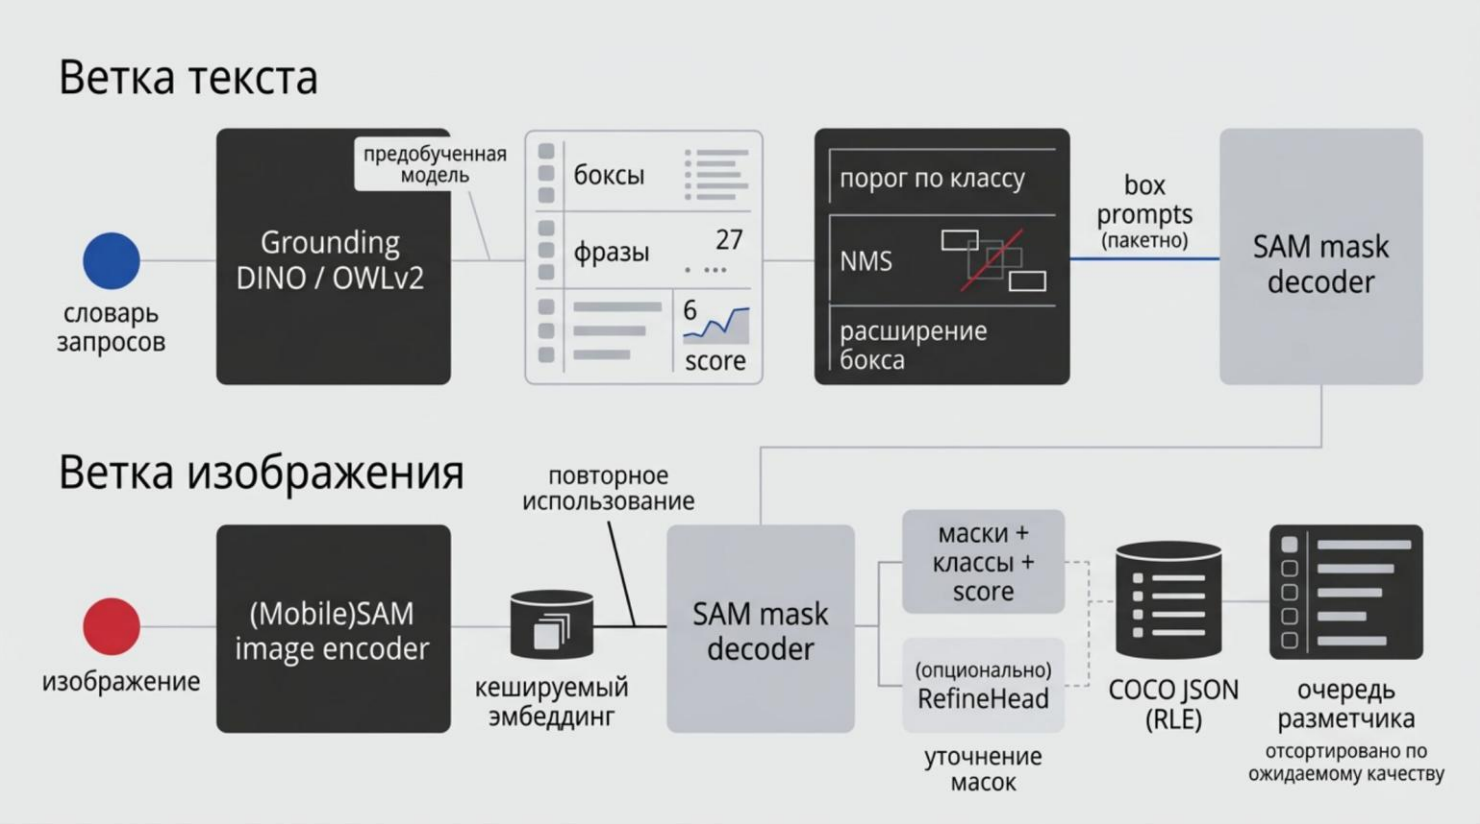
$$s = s_{\mathrm{det}} \cdot \mathrm{IoU}_{\mathrm{SAM}}$$

Порог, NMS, расширение бокса.

Ошибки наследуются: пропуск → FN; ложный бокс → FP; бокс на два объекта → слипшаяся маска.

OPEN-VOCABULARY · КОНВЕЙЕР

Конвейер open-vocabulary детектор → SAM



Порог подбирают по кривой precision–recall на валидации; для предразметки часто высокий recall.

ПРОТОКОЛ ОЦЕНКИ И SAM В РАЗМЕТКЕ

ОЦЕНКА · РЕЖИМЫ

Три режима сравнения

Ошибка: сравнивать SAM с подсказками из эталона и полностью автоматическую supervised-модель как равные.

Режим	Откуда prompts	Что измеряет
A. Oracle prompts	Эталонная маска: бокс с шумом δ, точка, клики	Качество «обводки» при известной локализации
B. Detector prompts	Закрытый детектор, обученный на train	Автоматическая instance segmentation
C. Open-vocabulary prompts	Текстовые запросы	Zero-shot без размеченных данных домена

Полезна кривая обучения baseline при 25, 50, 100, 200 изображениях.

ОЦЕНКА · МЕТРИКИ

Метрики

$$\mathrm{BIoU}(G, P) = \frac{\mid (G_d \cap G) \cap (P_d \cap P) \mid}{\mid (G_d \cap G) \cup (P_d \cap P) \mid}$$

G_d, P_d: пиксели на расстоянии не более d от контура; d = 2% диагонали (Cheng et al., 2021).

Каждая маска

IoU и Dice: среднее, медиана, распределение.

Взаимодействия

NoC@85 / NoC@90: число кликов до IoU ≥ 0,85 / 0,90.

Режимы B, C

Mask AP, AP50, AP75, AP_S/M/L, AR@100; типология TIDE.

Несколько seed; парный bootstrap по изображениям с 95% ДИ.

ОЦЕНКА · ОПЕРАЦИОННАЯ МЕТРИКА

Доля масок, требующих значительной правки

Значительная правка	Мелкая правка	Принять
$IoU < \tau_2$	$\tau_2 \le IoU < \tau_1$	$IoU \ge \tau_1$ и $BIoU \ge \beta$

Стартовые значения: $\tau_1 = 0{,}90$, $\tau_2 = 0{,}75$. FP: нет эталона с $IoU \ge 0{,}5$; FN: эталон без маски с $IoU \ge 0{,}5$.

$$p_{sig} = \frac{n_{sig} + n_{FN}}{n_{GT}}$$

$$\frac{p + \frac{z^2}{2n} \pm z\left(\frac{p(1-p)}{n} + \frac{z^2}{4n^2}\right)^{1/2}}{1 + \frac{z^2}{n}}, \qquad z = 1{,}96$$

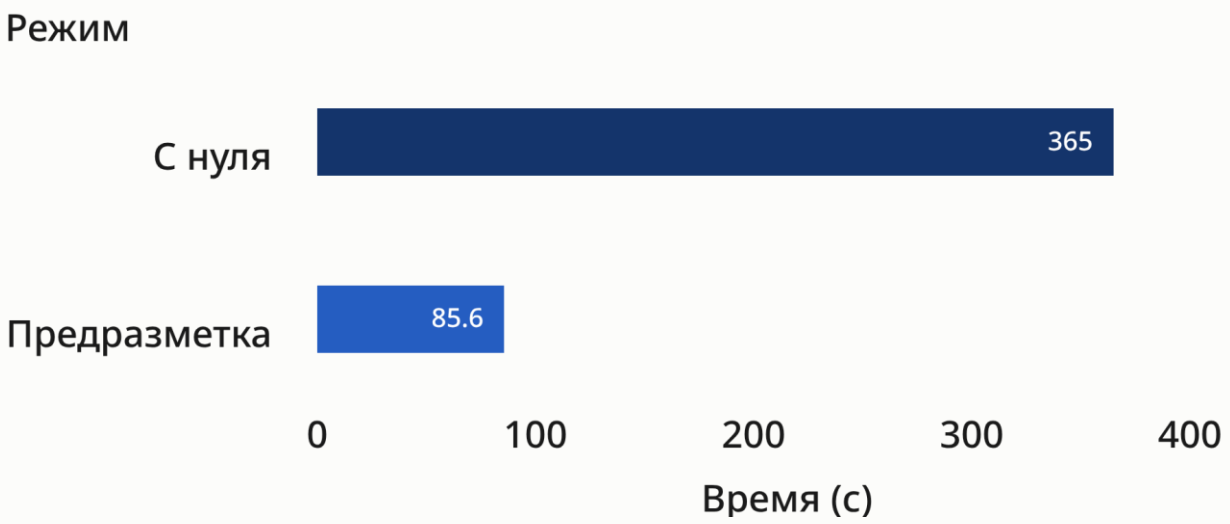
Интервал Уилсона; предпочтителен bootstrap по изображениям.

ОЦЕНКА · СТОИМОСТЬ

Стоимость ручной правки

$$T_{manual} = t_{open} + n \cdot t_m$$

$$T_{pre} = t_{open} + n[p_a t_{check} + p_{min} t_{min} + p_{sig} t_{sig} + p_{FN} t_m] + n_{FP} t_{del}$$



≈4,3 раза

Ускорение

При каком p_sig ускорение падает ниже 2 раз?

n=8; t_m=45 c; t_open=5 c; p_a=0,55; p_min=0,25; p_sig=0,12; p_FN=0,08; t_check=2 c; t_min=8 c; t_sig=25 c; n_FP=1,5; t_del=2 c.

T_manual = 5 + 8·45 = 365; T_pre = 5 + 8(0,55·2 + 0,25·8 + 0,12·25 + 0,08·45) + 1,5·2 = 5 + 8·9,7 + 3 = 85,6.

РАЗМЕТКА · РИСКИ

Сценарии использования и риски предразметки

Интерактивный

Предразметка

Детектор + SAM + RefineHead

Итеративный

Model-in-the-loop

Контроль ошибок

Automation bias: слепая разметка с нуля на случайной доле данных.

Систематические ошибки SAM переходят в обучающую выборку.

Происхождение и проверка

Test-выборка размечена вручную или полностью проверена человеком.

manual, pre_accepted, pre_minor_edit, pre_major_edit; проверка лицензий.

ИТОГИ

ИТОГИ

Итоги

1

SAM

Promptable-сегментатор: тяжёлый энкодер один раз, лёгкий декодер на каждую подсказку; семантики нет.

2

SAM 2

Добавляет память и видимость объекта.

3

Облегчённые версии

MobileSAM дистиллирует только энкодер; EfficientSAM использует признаки SAM как цель предобучения.

4

Адаптация

От дешёвой к дорогой: prompts → голова → декодер → адаптеры → полный fine-tuning.

5

Open-vocabulary

Детекторы дают SAM семантику и box prompts.

6

Операционная метрика

Доля масок со значительной правкой и пропусков.

ПРАКТИКА

Контрольные вопросы

01 Какие размеры имеет эмбеддинг изображения SAM и почему его выгодно кешировать?

02 Почему SAM выдаёт три маски и как выбирается маска для лосса?

03 Почему нельзя брать центр масс как автоматическую точку?

04 Зачем отдельно хранить кадры с подсказками в SAM 2?

05 Почему MobileSAM может использовать исходный декодер?

06 Почему последний слой refinement head инициализируется нулями?

07 Чем отличается слияние текста и изображения в OWL-ViT и Grounding DINO?

08 Почему bootstrap по изображениям, а не по маскам?